

RouteSAM: 通过跨图像语义路径实现半监督二维医学图像分割

作者信息待补充

摘要

医学图像的高昂标注成本使半监督学习成为医学图像分割中的重要研究方向。然而，当有限的标注数据难以充分覆盖多样化的病灶表征时，半监督分割模型往往会出现明显的性能下降。尤其是在标注数据与未标注数据之间存在较大语义差异的情况下，有限的标注信息难以稳定迁移至未标注图像，从而影响所生成伪监督的可靠性。为此，我们提出 RouteSAM，一种基于语义路由的渐进式监督传播方法。为使有限监督覆盖尽可能广泛的特征空间，RouteSAM 首先从训练数据中筛选具有较高特征覆盖性的样本，作为后续监督传播的起点。进一步地，针对未标注图像，RouteSAM 在其与已标注图像之间构建由多个特征相关图像组成的传播路径，使监督信息沿语义邻近的图像逐步传递，从而避免在特征差异较大的图像之间进行困难的直接迁移。在此基础上，我们进一步设计了一种多阶段的通用模型-专用模型协同机制，利用 SAM3 的通用分割能力与任务特定 U-Net 的医学域知识，通过伪监督的迭代筛选与模型间的协同适配，逐步提高监督信息的可靠性并增强模型对目标医学任务的适应能力。在 Kvasir-SEG、BUSI 和 ISIC2018 数据集上的实验结果表明，RouteSAM 在极少量标注数据下能够有效提升半监督医学图像分割性能，[最终定量结果待补充]。

关键词：半监督医学图像分割；sSegment Anything Model；跨图像传播；语义路径；伪标签学习

1 引言

医学图像分割能够对病灶、器官以及其他具有临床意义的解剖结构进行精细的空间勾画，是计算机辅助诊断、疾病定量评估和治疗方案制定等任务的重要基础。近年来，深度学习显著提升了医学图像分割的性能，但高性能分割模型通常需要大量高质量的像素级标注。相比自然图像，医学图像的精确标注往往需要医务人员投入较多时间并具备相应的专业知识，因此大规模医学图像标注数据的获取成本较高且难度较大 [Hesamian et al. \(2019\)](#); [Tajbakhsh et al. \(2020\)](#)。为降低对人工标注的依赖，半监督医学图像分割 (Semi-Supervised Medical Image Segmentation, SSMIS) 通过联合利用少量有标注数据和大量无标注数据，逐渐成为医学图像分割中的重要研究方向 [Jiao et al. \(2024\)](#)。

现有 SSMIS 方法主要通过伪标签学习与一致性正则化从无标注数据中获取额外监督。一类方法根据模型预测构造伪标签，并通过教师-学生结构或多个网络之间的协同学习不断更新监督信息；另一类方法则对输入、特征表示或模型自身施加扰动，并约束模型在不同扰动条件下保持预测一致。Cross Teaching、MC-Net+ 和 BCP 等代表性方法分别通过异构网络之间的相互监督、不确定性感知的一致性学习，以及有标注与无标注样本之间的双向混合，提高了无标注数据的利用效率 [Luo et al. \(2022\)](#); [Wu et al. \(2022\)](#); [Bai et al. \(2023\)](#)。然而，当人工标注样本进一步减少时，模型从有标注数据中能够学习到的可靠任务知识也会相应下降，由模型自身产生的伪标签因而更容易受到预测错误和不确定性的影响。

可提示分割基础模型的出现，为获取更强的监督信息带来了新的机会。Segment Anything Model (SAM) 及其后续模型通过大规模预训练获得了通用视觉表征能力和提示驱动的分割先验，可以根据点、框或掩码等提示对目标区域进行分割 [Kirillov et al. \(2023\)](#)。尽管自然图像与医学图像之间存在明显的领域差异，使 SAM 在不同医学影像任务上的直接分割表现并不稳定 [Mazurowski et al. \(2023\)](#); [Ma et al. \(2024\)](#)，其通过大规模预训练获得的通用分割知识仍具有较高的利用价值。因此，近年来已有研究开始将 SAM 引入半监督医学图像分割：利用任务特定模型生成提示，并通过 SAM 的预测结果构造或改善无标注数据上的伪监督。例如，SemiSAM 使用任务特定分割模型为 SAM 提供定位提示；SemiSAM+ 进一步建立了通用基础模型与任务特定专用模型之间的协作关系；SAMatch 则借助 SAM 对已有预测结果进行进一步优化 [Zhang et al. \(2024, 2025\)](#); [Xu et al. \(2024\)](#)。这些研究说明，基础模型中包含的通用分割先验可以成为无标注医学图像学习中的另一种监督来源。然而，现有方法大多仍将重点放在提升每一幅无标注图像自身的预测结果或伪标签质量上，尚未充分利用训练样本之间的跨样本语义关系。

值得注意的是，医学图像之间并非彼此独立，同类解剖结构或病灶在不同样本中往往存在可关联的语义模式。已有研究表明，不同医学图像之间存在可以利用的跨样本语义关系。例如，ACTION 同时建模全局语

义关系和局部解剖信息，以提升半监督表示学习效果，这说明训练样本之间并不一定需要被视为彼此完全独立的实例 You et al. (2022)。进一步地，YoloSeg 使用 SAM2 将单个已标注图像中的分割信息传播到无标注图像，展示了跨图像传播在极低标注环境中的潜力 Zhang et al. (2026)。然而，这类传播方式仍主要采用从有标注图像直接到目标图像的单跳传播形式。当两幅图像在病灶形态、尺度或外观方面存在较大的语义差异时，直接传播需要在一步之内跨越较大的图像间差异，因而容易产生不稳定的伪监督。这进一步引出了一个问题：是否可以利用无标注数据内部的样本关系，在已有监督与困难目标之间加入若干语义相关的中间图像，从而把一次较困难的直接传播拆解为若干更加局部的传播步骤？

围绕这一问题，我们进一步研究如何利用无标注数据内部的关系来组织有限监督的传播过程。我们将无标注训练集视为由样本间语义关系构成的潜在空间，并提出 **RouteSeg**。在固定的标注预算下，RouteSeg 首先从训练集中选择能够较广泛覆盖训练数据分布的已标注样本，并将其定义为 **Anchor**。对于每一个需要生成伪标签的无标注 **Target**，RouteSeg 从无标注数据中检索若干与之具有语义关联的图像作为 **Bridge**，再依据图像之间的跨样本关系将其排列成一条有序的语义路径 (*semantic route*):

$$A \rightarrow B_1 \rightarrow B_2 \rightarrow \dots \rightarrow B_K \rightarrow T. \quad (1)$$

随后，RouteSeg 基于 SAM3 沿这条语义路径执行渐进式跨图像传播 (*progressive cross-image propagation*)，逐步将 Anchor 中提供的分割信息传播到 Target。相较于直接传播，Bridge 的加入能够将一次跨度较大的图像间变化拆分为多个更加局部的传播过程。这样，无标注样本不再只是等待生成伪标签的 Target，它还可以在其他 Target 的语义路径中充当 Bridge，从而参与有限监督的扩展过程。由于不同的 Anchor 和语义路径可能针对同一个 Target 生成不同的掩码候选，因此直接使用全部传播结果可能会引入不可靠的伪监督。为此，RouteSeg 进一步对这些掩码候选进行质量评估，并选取可靠的路由伪标签 (*route-derived pseudo-labels*) 用于后续训练。被选中的伪标签与 Anchor 的真实标注共同用于训练任务特定的分割模型，该模型被称为 **specialist**；SAM3 则作为 **generalist**。Specialist 从目标医学数据中学习任务特定知识，并进一步对 generalist 的传播结果提供反馈，使基础模型的通用分割先验与医学任务中的领域知识形成互补。语义路由和跨图像传播只在训练阶段使用；在推理阶段，specialist 可以直接对单幅图像完成分割，不需要检索 Anchor、构建语义路径，也不需要额外的人工提示。

我们在 Kvasir-SEG、BUSI 和 ISIC2018 三个具有不同成像特点与病灶类型的二维医学图像分割数据集上评估 RouteSeg，并统一采用约 1% 的标注预算。实验将 RouteSeg 与具有代表性的半监督医学图像分割方法、SAM 辅助的低标注分割方法以及直接跨图像传播策略进行比较，从而考察跨图像监督路由 (*cross-image supervision routing*) 对于扩展有限监督的作用。此外，我们还针对 Anchor 选择、Bridge 的引入和语义路径构建等关键组成部分开展消融与分析，以研究不同路由设计如何影响伪监督质量和最终的分割性能。

本文的主要贡献概括如下：

- 我们提出 RouteSeg，一种面向极低标注半监督医学图像分割的跨图像监督路由框架。通过将无标注训练集视为由样本间语义关系构成的潜在空间，RouteSeg 使有限监督能够沿语义路径逐步传播。
- 我们提出 Coverage-Aware Anchor Selection 与 Anchor-Bridge-Target 语义路由机制。前者在固定标注预算下选择具有代表性的已标注样本作为 Anchor，后者检索语义相关的无标注 Bridge，并基于 SAM3 执行渐进式跨图像传播，将困难的直接传播拆分为多个局部步骤。
- 我们提出可靠的路由伪监督学习与 generalist-specialist 协同策略，从不同语义路径产生的掩码候选中筛选可靠伪标签，并利用 specialist 学习到的任务特定知识进一步改善 generalist 的传播结果。

2 相关工作

2.1 半监督医学图像分割

半监督医学图像分割旨在利用少量像素级标注和大量未标注图像降低医学分割的标注成本。现有方法主要围绕如何从未标注数据中获得可靠监督展开。一类代表性方法通过一致性约束或伪标签学习利用未标注样本。Mean Teacher 使用学生模型参数的指数滑动平均构建教师模型，并约束不同扰动下的预测一致性 Tarvainen and Valpola (2017)；Cross Pseudo Supervision 通过两个独立初始化的网络相互生成伪标签 Chen et al. (2021)；Cross Teaching 进一步利用 CNN 与 Transformer 不同的归纳偏置进行交叉监督 Luo et al. (2022)；

MC-Net+ 则通过多个具有差异性的解码器建模预测不确定性, 并利用相互一致性约束未标注数据 [Wu et al. \(2022\)](#)。这些方法逐步从单一教师监督扩展到多模型或异构模型之间的互补监督, 其核心仍是从模型自身对未标注图像的预测中构造训练信号。

在此基础上, 后续研究进一步关注伪监督的可靠性以及标注数据与未标注数据之间的有效交互。BCP 通过双向 Copy-Paste 在标注样本和未标注样本之间进行区域混合, 以减小两类数据之间的经验分布差异 [Bai et al. \(2023\)](#); ABD 根据预测置信度执行自适应的双向区域置换, 以控制扰动过程中引入的伪标签噪声 [Chi et al. \(2024\)](#); DyCON 则结合动态不确定性感知的一致性学习与对比学习, 对不同可靠程度的未标注区域进行差异化优化 [Assefa et al. \(2025\)](#)。总体而言, 这类方法主要从预测一致性、伪标签质量、数据扰动或局部样本交互的角度提升未标注数据的利用效率。相比之下, 本文关注的并不是如何进一步改进单个未标注样本上的预测约束, 而是如何利用未标注数据之间的语义关系, 显式组织稀疏分割监督在多张图像之间的传播过程。

2.2 基础模型辅助的少标注医学图像分割

随着 Segment Anything Model (SAM) 等通用分割基础模型的发展, 大规模预训练获得的分割先验开始被用于提升少标注医学图像分割中的监督质量。SemiSAM 在传统半监督框架中引入冻结的 SAM 辅助分支, 由任务模型根据未标注图像的预测生成提示, 并利用 SAM 输出提供额外的一致性监督 [Zhang et al. \(2024\)](#)。SemiSAM+ 进一步将这一思路扩展为通用模型与任务模型之间的协同学习, 通过置信度感知机制利用一个或多个冻结的基础模型增强未标注数据上的监督信号 [Zhang et al. \(2025\)](#)。SAMatch 则将弱到强的一致性学习与经过任务适配的 SAM 相结合, 由教师模型自动产生提示, 再通过 SAM 获得更完整的伪标签用于学生模型训练 [Xu et al. \(2024\)](#)。这类方法的共同思路是利用基础模型已有的分割先验, 对任务模型产生的定位信息或初始预测进行补充和修正, 从而提高单个未标注样本上的伪监督质量。

进一步的研究开始关注基础模型与任务模型之间更充分的双向知识交互。CPC-SAM 通过不同 SAM 解码分支之间的交叉提示与一致性约束增强未标注样本学习 [Miao et al. \(2024\)](#); SC-SAM 使用任务专用 U-Net 为 SAM 提供点提示和伪标签以进行参数高效适配, 同时利用 SAM 的预测反向约束任务模型 [Vu et al. \(2026\)](#); CPPS-SAM 则通过交叉提示和交叉伪监督, 在 CNN 专家模型与 SAM 通用模型之间实现双向知识传递 [Zhang and He \(2026\)](#)。这些工作表明, 通用分割先验与任务特定知识之间的互补能够有效改善少标注条件下的监督学习。然而, 现有协同机制主要围绕同一未标注图像上的提示生成、预测修正和模型交互展开, 尚未进一步利用不同未标注图像之间的语义联系来组织监督的跨图像传播。RouteSeg 则从这一角度出发, 将基础模型的作用由单图伪标签增强进一步扩展到跨图像监督传播过程。

2.3 跨图像关系建模与监督传播

除单图像上的一致性学习与伪标签优化外, 一些研究开始显式利用不同样本之间的关系来增强半监督表示学习。ACTION 通过全局语义关系与局部解剖对比进行知识蒸馏, 以利用数据集内部的跨样本结构 [You et al. \(2022\)](#); DACL 构建密度感知的邻域关系, 将稀疏区域特征向高密度类别区域聚合 [Tang et al. \(2024\)](#); GraphCL 则通过实例图与图聚类对不同样本间的结构信息进行建模 [Wang et al. \(2024\)](#)。这些工作说明未标注医学图像之间并非相互独立, 其潜在的邻域关系和语义结构能够为模型学习提供额外信息。然而, 这类方法主要将跨样本关系用于特征约束、对比学习或聚类优化, 并未直接将这种关系转化为分割监督在图像之间的传播过程。

另一类与本文更为接近的方法直接利用参考图像或已标注样本向目标图像传递分割信息。PerSAM 根据单个参考图像及其掩码对 SAM 进行个性化, 使其能够在目标图像中识别对应对象 [Zhang et al. \(2023\)](#); Matcher 通过通用视觉特征匹配实现 one-shot 条件下的目标区域迁移 [Liu et al. \(2023\)](#); OP-SAM 利用支持图像与查询图像之间的特征相关性和迭代提示, 将单个标注样本中的息肉先验传递到目标图像 [Mao et al. \(2025\)](#)。进一步地, YoloSeg 使用 SAM2 的传播能力将单个标注样本扩展到未标注数据, 并通过多视图共识与差异区域学习抑制传播噪声, 最终训练任务专用分割模型 [Zhang et al. \(2026\)](#)。这些方法证明了利用基础模型进行跨图像监督迁移的可行性, 但其传播过程主要围绕标注源与目标图像之间的直接对应关系展开。

RouteSeg 进一步关注在标注源与困难目标之间是否存在可用于过渡的未标注样本。与直接从单个支持样本向目标传递监督不同, RouteSeg 将未标注数据集视为一个由样本间语义关系构成的潜在传播空间, 并主动选择和排序中间图像, 使监督能够沿由 Anchor、Bridge 和 Target 组成的有序路径逐步传递。由此, 未标注图像不再仅作为等待生成伪标签的目标样本, 而是同时作为连接稀疏标注与困难目标的中间语义节点。

3 方法

3.1 问题定义与整体框架

本文研究极低标注条件下的半监督二维医学图像分割。设训练集为

$$\mathcal{D}_{\text{tr}} = \{x_i\}_{i=1}^N,$$

其中仅允许对极少量训练图像获取像素级人工标注，其余图像在训练过程中均不使用真实分割掩码。给定固定的标注预算 K ，本文首先从训练集中确定 K 幅图像并获得其人工标注，将这些图像记为有标注集合

$$\mathcal{D}_L = \{(x_a, y_a)\}_{a=1}^K,$$

其余训练图像构成未标注集合

$$\mathcal{D}_U = \{x_t\}_{t=1}^{N-K}.$$

本文主要考虑约 1% 的标注比例，即只有训练集中极少部分图像能够直接提供可靠的像素级监督。

在这种条件下，一个直接的思路是利用已有标注图像中的分割信息，为未标注图像生成伪标签。随着 SAM 等可提示分割基础模型的发展，这种跨图像监督迁移成为可能：给定一幅具有人工标注的图像，可以利用其目标信息辅助基础模型在另一幅未标注图像上寻找对应区域。然而，这种直接传播隐含了一个较强的假设，即提供监督的已标注图像与待处理图像之间具有足够相近的目标外观。当两幅图像在病灶形态、尺度、位置或成像特征上存在较大差异时，从已标注图像直接传播到待处理图像需要一次跨越较大的图像间变化，传播得到的目标区域因而容易出现偏移、缺失或形态失真。

以一幅有标注图像 x_a 和一幅未标注图像 x_t 为例，直接跨图像传播可以表示为

$$x_a \rightarrow x_t.$$

这一过程将监督从 x_a 一次性迁移到 x_t 。然而，大规模未标注训练集并不只包含最终需要生成伪标签的图像。在 x_a 与 x_t 之间，往往还存在一些在目标外观上逐渐发生变化的训练样本。如果这些图像能够作为中间状态参与传播，则原本跨度较大的直接迁移可以被拆分为若干更加局部的跨图像变化。

基于这一观察，本文提出 RouteSAM。其核心思想是将未标注训练集不仅视为需要生成伪标签的样本集合，同时视为可用于连接有限人工监督与不同未标注图像的潜在传播空间。对于待处理图像 x_t ，RouteSAM 不直接从某一有标注图像向其传播分割信息，而是在二者之间寻找若干语义相关的未标注图像，并按照图像间的相关性将其组织为有序的传播路径。记这些中间图像为

$$x_{b_1}, x_{b_2}, \dots, x_{b_L},$$

则一条传播路径可表示为

$$x_a \rightarrow x_{b_1} \rightarrow x_{b_2} \rightarrow \dots \rightarrow x_{b_L} \rightarrow x_t.$$

本文将位于传播起点与待处理图像之间的这些中间样本称为语义中间图像，并将上述有序图像序列称为语义路径。通过这种方式，一次较困难的直接跨图像传播被分解为多个相邻样本之间的渐进传播过程，使分割信息能够沿训练数据中的语义连续关系逐步到达待处理图像。

基于这一思想，RouteSAM 的整体框架包含三个相互衔接的步骤。首先，由于人工标注数量十分有限，需要使这些有限监督尽可能覆盖训练数据中不同的视觉模式，因此本文从训练集中选择具有较好分布覆盖性的图像作为人工监督来源。随后，对于每一幅未标注图像，根据其目标特征从已有标注样本中确定合适的传播起点，并进一步在未标注训练集中搜索与传播过程相关的中间图像，构建从有标注样本到待处理图像的有序语义路径。最后，将该路径中的图像按照顺序输入 SAM3，使分割信息从人工标注图像出发，经过若干中间图像逐步传播至待处理图像，从而得到其伪分割掩码。

对未标注训练集中的图像重复上述过程后，可以得到路由传播产生的伪标注集合

$$\hat{\mathcal{D}}_U = \{(x_t, \hat{y}_t) \mid x_t \in \mathcal{D}_U\},$$

其中 $\hat{y}_t$ 表示沿语义路径传播得到的伪标签。最终，人工标注数据 $\mathcal{D}_L$ 与路由伪标注数据 $\hat{\mathcal{D}}_U$ 被共同用于训练任务特定的分割网络。语义路径构建和 SAM3 跨图像传播仅用于训练阶段的监督扩展；测试时，训练完成的分割网络直接接收单幅图像并输出分割结果，不再需要参考图像、语义路径或额外人工提示。

3.2 覆盖感知的监督起点选择

在极低标注条件下，可获得人工标注的训练样本数量十分有限。这些样本不仅用于提供直接的像素级监督，同时也是后续跨图像传播的起点。因此，如果少量有标注样本集中于相似的病灶外观或局部数据区域，即使后续传播过程保持不变，一些与这些样本差异较大的未标注图像仍然需要从较远的监督来源开始传播。为减小这种由监督起点覆盖不足带来的影响，本文不采用独立随机抽样，而是在固定标注预算下，从训练候选池中选择一组能够共同表征主要图像外观模式的样本。

记经过数据集级预处理并冻结后的训练候选池为

$$\mathcal{C} = \{x_i\}_{i=1}^{N_c}, \quad (2)$$

需要选择的样本集合记为 $\mathcal{A} \subseteq \mathcal{C}$ ，其中 $|\mathcal{A}| = K$ 。候选池冻结以后，选择过程仅使用训练图像的 RGB 信息，不读取候选样本的分割掩码，也不利用验证集、测试集或下游分割性能。由于本模块的目的并不是预测病灶位置，而是衡量不同训练图像所包含局部视觉模式的相似程度，因此我们利用冻结的 SAM3 视觉骨干提取局部表征，并进一步将其转换为图像级视觉词分布。

对于候选图像 x_i ，首先将其缩放至 1008×1008 ，并输入冻结的 SAM3 图像编码器，得到空间分辨率为 72×72 、通道维度为 1024 的特征图

$$\mathbf{X}_i \in \mathbb{R}^{72 \times 72 \times 1024}. \quad (3)$$

该特征图中的每一个空间位置对应一个 1024 维局部视觉 token。直接使用全部 72×72 个 token 会产生大量高度相关的局部表示，因此本文沿两个空间方向分别均匀选取 8 个位置，并由其组合形成固定的 8×8 采样网格。由此，每幅图像获得 64 个覆盖不同空间区域的局部 token。需要指出的是，这里的 8×8 表示在 72×72 token 网格上的均匀位置采样，而非将原始图像重新划分为 8×8 个图像块。记图像 x_i 的第 r 个采样 token 为 $\mathbf{x}_{ir}$ ，在构建视觉词典之前对其进行 L_2 归一化：

$$\hat{\mathbf{x}}_{ir} = \frac{\mathbf{x}_{ir}}{\max(\|\mathbf{x}_{ir}\|_2, \epsilon)}, \quad r = 1, \dots, 64, \quad (4)$$

其中 ϵ 为防止数值不稳定而引入的极小常数。

为了将不同图像中的局部表征转换为可比较的统计表示，我们汇总候选池中所有采样 token，并采用 Mini-Batch K-Means 学习包含 $M = 64$ 个聚类中心的共享视觉词典。每个局部 token 被分配到距离最近的聚类中心，由此可以统计一幅图像中不同视觉词的出现频率。对于第 m 个视觉词，图像 x_i 的词频定义为

$$\text{tf}_{im} = \frac{1}{64} \sum_{r=1}^{64} \mathbb{I}[q(\hat{\mathbf{x}}_{ir}) = m], \quad (5)$$

其中 $q(\cdot)$ 表示最近视觉词分配函数， $\mathbb{I}[\cdot]$ 为指示函数。

由于部分局部模式可能广泛存在于大多数训练图像中，例如相似的背景、组织纹理或成像结构，仅根据出现频率会使这些高频模式在图像相似度中占据过大权重。为降低此类共有模式的影响，我们进一步根据整个训练候选池统计逆文档频率。设包含视觉词 m 的图像数量为

$$\text{df}_m = \sum_{i=1}^{N_c} \mathbb{I}[\text{tf}_{im} > 0], \quad (6)$$

则其逆文档频率定义为

$$\text{idf}_m = \log \frac{N_c + 1}{\text{df}_m + 1} + 1. \quad (7)$$

由此得到图像 x_i 在第 m 个视觉词上的加权响应

$$w_{im} = \text{tf}_{im} \text{idf}_m, \quad (8)$$

并将其归一化为视觉词概率分布

$$p_{im} = \frac{w_{im}}{\sum_{l=1}^M w_{il}}. \quad (9)$$

因此，每幅图像最终由一个 M 维离散分布

$$\mathbf{p}_i = (p_{i1}, p_{i2}, \dots, p_{iM}) \quad (10)$$

描述。该表示反映了不同局部视觉模式在整幅图像中的组成关系，而不依赖任何病灶掩码或预先指定的目标区域。

在此基础上，我们采用 Hellinger 映射对视觉词分布进行变换：

$$\phi_i = (\sqrt{p_{i1}}, \sqrt{p_{i2}}, \dots, \sqrt{p_{iM}}). \quad (11)$$

由于

$$\sum_{m=1}^M p_{im} = 1, \quad (12)$$

因此有 $\|\phi_i\|_2 = 1$ 。两幅图像 x_i 和 x_j 的相似度可表示为

$$k(i, j) = \phi_i^\top \phi_j = \sum_{m=1}^M \sqrt{p_{im} p_{jm}}. \quad (13)$$

该相似度即两个视觉词分布之间的 Bhattacharyya 系数，并与平方 Hellinger 距离满足

$$H^2(\mathbf{p}_i, \mathbf{p}_j) = 1 - k(i, j). \quad (14)$$

因此， $k(i, j)$ 越大，说明两幅图像包含的局部视觉模式及其分布越接近。相比直接平均所有局部特征，该表示更关注图像中不同视觉模式的组成，同时降低在整个数据集中普遍出现的高频模式对相似度计算的影响。

得到候选图像之间的相似度后，需要进一步从中选择 K 幅能够共同覆盖训练数据主要视觉模式的图像。为此，我们采用 facility-location 形式的集合覆盖目标。对于任意候选集合 $\mathcal{A}$ ，定义

$$F(\mathcal{A}) = \frac{1}{N_c} \sum_{i=1}^{N_c} \max_{a \in \mathcal{A}} k(i, a). \quad (15)$$

其中， $\max_{a \in \mathcal{A}} k(i, a)$ 表示训练图像 x_i 与当前所选样本中最相近图像之间的相似度。因此， $F(\mathcal{A})$ 衡量的是整个候选池能够在多大程度上被所选样本集合表征。当多个入选样本具有高度相似的视觉词分布时，它们对于 $F(\mathcal{A})$ 的新增贡献较小；相反，能够覆盖当前集合尚未充分表示的数据区域的样本会获得更大的边际增益。

在固定基数约束 $|\mathcal{A}| = K$ 下，我们采用贪心策略逐步构造最终集合。设第 $t-1$ 次迭代后已选择集合为 $\mathcal{A}_{t-1}$ ，则下一幅图像由

$$a_t = \arg \max_{j \notin \mathcal{A}_{t-1}} [F(\mathcal{A}_{t-1} \cup \{j\}) - F(\mathcal{A}_{t-1})] \quad (16)$$

确定，并更新

$$\mathcal{A}_t = \mathcal{A}_{t-1} \cup \{a_t\}. \quad (17)$$

由于本文使用的相似度非负， $F(\mathcal{A})$ 构成单调次模的 facility-location 目标。在固定集合大小约束下，标准贪心选择具有经典的 $1 - 1/e$ 近似保证。需要说明的是，该理论保证针对所定义的视觉覆盖目标，而非直接针对后续分割性能。

经过 K 次迭代后得到最终监督起点集合 $\mathcal{A}$ 。只有在该集合完全确定后，才获取这些入选图像对应的人工分割掩码，并据此生成后续跨图像传播所需的目标提示。这样，少量人工监督在进入语义路由之前首先获得较为分散的训练分布覆盖，为后续针对不同未标注图像选择合适传播来源提供更多具有差异性的起始条件。

3.3 面向待处理图像的语义路由构建

上一节得到的监督起点集合旨在从整体上覆盖训练数据中的不同视觉模式，但对于某一具体的未标注图像，并非所有起始样本都具有相同的传播价值。若直接根据整幅图像的全局相似性选择传播来源，背景、成像区域或其他与分割目标无关的结构可能对匹配结果产生较大影响。相比之下，已有人工标注能够提供关于目标区域的更直接信息。因此，对于每一幅待处理图像，本文首先利用已标注样本中的前景区域构造目标条件下的相似性度量，再在此基础上搜索由若干语义相关图像组成的有序传播路径。

与第 3.2 节用于监督起点选择的 1008×1008 表征不同，语义路由阶段统一在 256×256 分辨率下提取特征，以与后续传播过程保持一致。对于任意图像 x_i ，将其输入冻结的 SAM3 视觉骨干，并记输出的 P 个局部 token 为

$$\mathbf{Z}_i = \{\mathbf{z}_{ip}\}_{p=1}^P, \quad \|\mathbf{z}_{ip}\|_2 = 1. \quad (18)$$

同时, 对所有局部 token 取均值并进行 L_2 归一化, 得到图像级描述子

$$\mathbf{g}_i = \text{norm} \left(\frac{1}{P} \sum_{p=1}^P \mathbf{z}_{ip} \right), \quad (19)$$

其中 $\text{norm}(\mathbf{v}) = \mathbf{v} / \|\mathbf{v}\|_2$ 。该描述子用于刻画候选中间图像之间的整体视觉连续性。

对于任一已标注起始样本 $x_a \in \mathcal{A}$, 首先将其人工分割掩码映射到 SAM3 的 token 网格, 并记前景位置集合为 Ω_a 。利用这些前景位置对应的局部 token, 可以得到该起始样本的前景原型

$$\mathbf{u}_a = \text{norm} \left(\frac{1}{|\Omega_a|} \sum_{p \in \Omega_a} \mathbf{z}_{ap} \right). \quad (20)$$

与直接使用整幅起始图像相比, $\mathbf{u}_a$ 主要描述人工标注目标区域的视觉特征, 从而使后续匹配更加关注需要传播的分割对象。

给定起始样本 x_a 和任意候选图像 x_i , 我们首先计算前景原型 $\mathbf{u}_a$ 与 x_i 中各局部 token 之间的相似度, 并通过 softmax 进行加权聚合。具体而言, 令

$$m_{ai} = \max_p \mathbf{u}_a^\top \mathbf{z}_{ip}, \quad (21)$$

则第 p 个局部位置的权重为

$$\alpha_{aip} = \frac{\exp [\beta (\mathbf{u}_a^\top \mathbf{z}_{ip} - m_{ai})]}{\sum_q \exp [\beta (\mathbf{u}_a^\top \mathbf{z}_{iq} - m_{ai})]}, \quad (22)$$

其中温度系数固定为 $\beta = 10$ 。由此得到起始样本条件下的候选图像表示

$$\mathbf{h}_{a,i} = \text{norm} \left(\sum_p \alpha_{aip} \mathbf{z}_{ip} \right), \quad (23)$$

并定义目标相关得分

$$s(a, i) = \mathbf{h}_{a,i}^\top \mathbf{u}_a. \quad (24)$$

该得分衡量候选图像中是否存在与起始样本前景目标相近的局部区域。整个计算过程仅使用起始样本的人工掩码; 对于中间图像和待处理图像, 只读取其 RGB 信息。

不同起始样本对应的前景原型可能具有不同的相似度基线。例如, 某些原型可能对大量训练图像都产生偏高的匹配得分, 从而在跨起始样本比较时获得不合理的优势。为减小这种固定偏移, 我们仅利用训练图像的 RGB 特征对每个起始样本进行中心化校准。具体定义

$$\mu_a = \frac{1}{|\mathcal{D}_{\text{tr}}|} \sum_{x_i \in \mathcal{D}_{\text{tr}}} s(a, i), \quad (25)$$

并将校准后的目标相关得分表示为

$$\tilde{s}(a, i) = s(a, i) - \mu_a. \quad (26)$$

中心化操作仅消除不同起始样本之间的整体分数偏移, 不改变同一起始样本下不同图像之间的相对关系, 也不使用验证集、测试集或未标注图像的真实分割信息。

在得到起始样本条件下的目标相关性后, RouteSAM 并不直接将得分最高的起始样本与待处理图像连接, 而是进一步利用未标注训练数据中的中间状态构造语义连续的传播路径。对于待处理图像 x_t , 一条包含 L 个中间图像的候选路径记为

$$\mathcal{R} = (x_a, x_{b_1}, x_{b_2}, \dots, x_{b_L}, x_t), \quad (27)$$

其中 $x_a \in \mathcal{A}$ 为人工标注的传播起点, $x_{b_l} \in \mathcal{D}_{\text{tr}}$ 为训练集中选取的中间图像。路径中的起始样本、待处理图像以及各中间图像均不重复。

一条有效的传播路径需要同时满足两个条件。一方面, 其中的中间图像应持续包含与起始目标相关的视觉区域, 因此我们利用中心化后的目标相关得分 $\tilde{s}(a, b_l)$ 和 $\tilde{s}(a, t)$ 衡量各路径节点相对于起始目标的相关程度。另一方面, 相邻图像之间不应发生过大的视觉跳变。为此, 对于任意相邻图像 x_i 和 x_j , 根据其图像级描述子定义

$$s_{\text{rgb}}(i, j) = \mathbf{g}_i^\top \mathbf{g}_j. \quad (28)$$

前者保证路径中的图像始终围绕需要传播的目标语义，后者则约束监督传播过程中相邻图像之间的整体视觉变化。

将一条候选路径中的目标相关得分与相邻图像相似度统一记为数值集合

$$\mathcal{V}(\mathcal{R}) = \{\tilde{s}(a, b_1), \dots, \tilde{s}(a, b_L), \tilde{s}(a, t), s_{\text{rgb}}(x_a, x_{b_1}), \dots, s_{\text{rgb}}(x_{b_L}, x_t)\}. \quad (29)$$

如果仅最大化这些数值的平均值，一条路径可能在大多数位置具有较高相似度，却仍包含某一次明显的语义跳变。对于逐步传播而言，这样的局部失配可能成为整条路径中最容易发生传播错误的位置。因此，本文首先关注路径中的最弱环节，并在此基础上进一步比较路径的整体相关性。候选路径的评分定义为

$$Q(\mathcal{R}) = \left(\min_{v \in \mathcal{V}(\mathcal{R})} v, \frac{1}{|\mathcal{V}(\mathcal{R})|} \sum_{v \in \mathcal{V}(\mathcal{R})} v \right). \quad (30)$$

两个分量按照字典序进行比较，即优先选择最小路径值更高的候选；仅当最小值相同时，再比较其平均得分。该设计使路径搜索优先避免局部出现明显不匹配的中间状态，而不是仅依赖较高的整体平均相似度。

由于在整个训练集中穷举所有可能的中间图像组合计算开销较大，我们采用束搜索逐步扩展候选路径。每次扩展时，根据图像级描述子 $\mathbf{g}_i$ 的余弦相似度从训练集中获得与当前节点相近的候选图像，并利用上述路径评分保留得分最高的部分候选。本文将束宽固定为 32，并在不同起始样本对应的候选路径之间使用相同的评分准则进行比较，最终为每一幅待处理图像确定一条传播路径。

在正式方法中，我们在所有数据集和待处理图像上统一使用 $L = 6$ 个中间图像，因此最终路径写为

$$\mathcal{R}_t^* = (x_a, x_{b_1}, x_{b_2}, \dots, x_{b_6}, x_t). \quad (31)$$

中间图像数量在测试阶段不根据目标图像、真实标注或预测结果进行动态调整。不同路径长度的影响将在实验部分通过消融实验进一步分析。得到的有序图像序列随后作为下一节渐进式跨图像传播的输入。

3.4 基于 SAM3 的渐进式跨图像传播

经过上一节的语义路由构建后，每一幅待处理图像 x_t 均对应一条由人工标注起始样本、若干语义中间图像以及待处理图像组成的有序路径

$$\mathcal{R}_t^* = (x_a, x_{b_1}, x_{b_2}, \dots, x_{b_6}, x_t). \quad (32)$$

该路径确定了监督信息从已有人工标注逐步到达待处理图像的传播顺序。与直接将 x_a 和 x_t 构造成单次跨图像迁移不同，RouteSAM 将路径中的中间图像显式纳入传播过程，使目标信息能够沿相邻图像之间较为连续的视觉变化逐步传递。

为利用 SAM3 已有的时序掩码传播能力，我们将路径 $\mathcal{R}_t^*$ 中的图像按照既定顺序组织为一段短伪视频：

$$\mathcal{V}_t = [x_a, x_{b_1}, x_{b_2}, \dots, x_{b_6}, x_t]. \quad (33)$$

这里的“伪视频”并不要求这些图像来源于真实连续视频，而是将经过语义路由排序后的独立训练图像视为一个有序帧序列。其目的在于利用 SAM3 的跨帧目标保持与掩码传播能力，将起始样本中的目标信息沿所构建的语义路径逐步传递。

所有路径帧均双线性缩放至 256×256 ，该分辨率与上一节中的路由特征提取保持一致。对于首帧 x_a ，人工分割掩码 y_a 仅用于生成目标的紧致外接框

$$\mathbf{b}_a = \text{Box}(y_a), \quad (34)$$

其中 $\text{Box}(\cdot)$ 表示包含前景区域的最小轴对齐外接框。该外接框作为 SAM3 在首帧上的正框提示，用于初始化需要沿路径跟踪和传播的目标。除首帧外，中间图像和待处理图像均不提供人工点、框或掩码提示，整个传播过程也不使用文本提示。

在完成首帧初始化后，冻结的 SAM3 按照路径顺序执行前向传播。记第 l 个中间图像上的预测掩码为 $\hat{y}_{b_l}$ ，则整个传播过程可写为

$$(x_a, y_a) \rightarrow \hat{y}_{b_1} \rightarrow \hat{y}_{b_2} \rightarrow \dots \rightarrow \hat{y}_{b_6} \rightarrow \hat{y}_t. \quad (35)$$

其中，前一帧中建立的目标状态被持续传递到后续帧，使 SAM3 能够在新的图像内容中更新目标位置和分割区域。需要强调的是，中间图像的预测掩码仅作为传播过程中内部维护的目标状态，不被视为人工监督，也不会读取其对应的真实分割标注。

从概率角度看，直接传播可以理解为试图一次完成

$$p(y_t | x_a, y_a, x_t), \quad (36)$$

而 RouteSAM 将其展开为沿语义路径进行的连续条件传播：

$$p(y_t | x_a, y_a, x_{b_1}, \dots, x_{b_6}, x_t). \quad (37)$$

通过在起始样本与待处理图像之间引入若干语义相关的中间状态，原本较大的跨图像变化被分散到多个相邻传播步骤中。这样，SAM3 在每一步所面对的目标外观变化相对更加局部，从而为监督信息逐步到达困难样本提供了更稳定的传播条件。

对于每一幅待处理图像，本文仅保留语义路径末端得到的目标掩码作为最终传播结果，即

$$\hat{y}_t = \text{SAM3Propagate}(\mathcal{R}_t^*, \mathbf{b}_a). \quad (38)$$

若 SAM3 在目标帧产生多个候选对象，则选取模型内部置信度最高的预测作为该路径的最终输出。整个传播过程中 SAM3 参数保持冻结，不对其进行微调，也不利用待处理图像的真实掩码参与传播或结果选择。

因此，对于未标注集合中的全部样本，可以得到由语义路径传播生成的伪标注集合

$$\hat{\mathcal{D}}_U = \{(x_t, \hat{y}_t) | x_t \in \mathcal{D}_U\}. \quad (39)$$

这些伪标签将与少量人工标注共同构成后续任务分割网络的训练监督。需要指出的是，语义路由与 SAM3 传播的作用仅在于训练阶段扩展有限人工监督，其本身不参与最终单图像分割模型的测试推理。

3.5 路由伪监督学习与最终推理

经过前述语义路由与渐进式跨图像传播后，未标注训练集中的每一幅图像 $x_t \in \mathcal{D}_U$ 均获得一个由固定六桥路径传播得到的伪分割掩码 $\hat{y}_t$ 。这些伪标签将原本仅存在于少量人工标注样本中的像素级监督扩展到更大范围的训练数据，从而为任务特定分割模型提供额外的训练信号。本文不再对不同传播深度产生的候选结果进行额外筛选，而是统一采用第 3.4 节得到的固定六桥传播结果作为未标注样本的训练监督。

记人工标注数据为

$$\mathcal{D}_L = \{(x_a, y_a) | x_a \in \mathcal{A}\}, \quad (40)$$

路由传播产生的伪标注数据为

$$\hat{\mathcal{D}}_U = \{(x_t, \hat{y}_t) | x_t \in \mathcal{D}_U\}. \quad (41)$$

最终训练集由二者共同组成：

$$\mathcal{D}^* = \mathcal{D}_L \cup \hat{\mathcal{D}}_U. \quad (42)$$

为使最终性能提升尽可能归因于前述监督路由过程，而非额外的复杂分割结构，本文采用标准 U-Net 作为任务特定分割模型，记为 $f_\theta(\cdot)$ 。对于人工标注样本，其监督损失定义为

$$\mathcal{L}_{\text{sup}} = \frac{1}{|\mathcal{D}_L|} \sum_{(x_a, y_a) \in \mathcal{D}_L} \ell(f_\theta(x_a), y_a), \quad (43)$$

其中 $\ell(\cdot)$ 由像素级交叉熵损失和 soft Dice 损失共同组成。对于未标注训练样本，则利用 RouteSAM 产生的伪标签构造

$$\mathcal{L}_{\text{pseudo}} = \frac{1}{|\hat{\mathcal{D}}_U|} \sum_{(x_t, \hat{y}_t) \in \hat{\mathcal{D}}_U} \ell(f_\theta(x_t), \hat{y}_t). \quad (44)$$

最终优化目标写为

$$\mathcal{L} = \mathcal{L}_{\text{sup}} + \lambda_u \mathcal{L}_{\text{pseudo}}, \quad (45)$$

其中 λ_u 用于平衡少量人工监督与大规模路由伪监督对模型优化的影响。

这种训练方式有意保持下游分割学习过程的简单性。RouteSAM 的主要作用并不是重新设计伪标签学习损失或构造新的任务分割网络，而是改善未标注数据上监督信号的来源。与直接利用单跳跨图像传播获得伪标签相比，本文首先根据训练数据内部的语义关系构建传播路径，再利用 SAM3 沿该路径逐步扩展人工监督。因此，最终 U-Net 接收到的附加监督主要由前述跨图像监督路由过程决定，而无需进一步依赖候选质量预测、模型间审核或多轮伪标签更新。

语义路由和 SAM3 传播均只用于训练阶段。给定测试图像 x ，最终预测直接由训练完成的 U-Net 得到：

$$\hat{y} = f_{\theta}(x). \quad (46)$$

测试过程中不再访问人工标注起始样本，不需要在训练数据中检索语义相近图像，也无需重新构建传播路径或调用 SAM3。由此，RouteSAM 将计算开销相对较高的跨图像关系建模集中在离线训练阶段，而在实际推理时仍保持标准单图像分割模型的预测形式。

参考文献

- Maregu Assefa, Muzammal Naseer, Iyyakutti Iyappan Ganapathi, Syed Sadaf Ali, Mohamed L. Seghier, and Naoufel Werghi. DyCON: Dynamic uncertainty-aware consistency and contrastive learning for semi-supervised medical image segmentation. *arXiv preprint arXiv:2504.04566*, 2025.
- Yunhao Bai, Duowen Chen, Qingli Li, Wei Shen, and Yan Wang. Bidirectional copy-paste for semi-supervised medical image segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11514–11524, 2023. doi: 10.1109/CVPR52729.2023.01108.
- Xiaokang Chen, Yuhui Yuan, Gang Zeng, and Jingdong Wang. Semi-supervised semantic segmentation with cross pseudo supervision. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2613–2622, 2021. doi: 10.1109/CVPR46437.2021.00264.
- Hanyang Chi, Jian Pang, Bingfeng Zhang, and Weifeng Liu. Adaptive bidirectional displacement for semi-supervised medical image segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 4070–4080, 2024. doi: 10.1109/CVPR52733.2024.00390.
- Mohammad Hesam Hesamian, Wenjing Jia, Xiangjian He, and Paul Kennedy. Deep learning techniques for medical image segmentation: Achievements and challenges. *Journal of Digital Imaging*, 32(4):582–596, 2019. doi: 10.1007/s10278-019-00227-x.
- Rushi Jiao, Yichi Zhang, Le Ding, Bingsen Xue, Jicong Zhang, Rong Cai, and Cheng Jin. Learning with limited annotations: A survey on deep semi-supervised learning for medical image segmentation. *Computers in Biology and Medicine*, 169:107840, 2024. doi: 10.1016/j.compbimed.2023.107840.
- Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollár, and Ross Girshick. Segment anything. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 4015–4026, 2023. doi: 10.1109/ICCV51070.2023.00371.
- Yang Liu, Muzhi Zhu, Hengtao Li, Hao Chen, Xinlong Wang, and Chunhua Shen. Matcher: Segment anything with one shot using all-purpose feature matching. *arXiv preprint arXiv:2305.13310*, 2023.
- Xiangde Luo, Minhao Hu, Tao Song, Guotai Wang, and Shaoting Zhang. Semi-supervised medical image segmentation via cross teaching between CNN and transformer. In *Proceedings of the 5th Conference on Medical Imaging with Deep Learning*, volume 172 of *Proceedings of Machine Learning Research*, pages 820–833, 2022.
- Jun Ma, Yuting He, Feifei Li, Lin Han, Chenyu You, and Bo Wang. Segment anything in medical images. *Nature Communications*, 15:654, 2024. doi: 10.1038/s41467-024-44824-z.

- Xinyu Mao, Xiaohan Xing, Fei Meng, Jianbang Liu, Fan Bai, Qiang Nie, and Max Meng. One polyp identifies all: One-shot polyp segmentation with SAM via cascaded priors and iterative prompt evolution. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2025.
- Maciej A. Mazurowski, Haoyu Dong, Hanxue Gu, Jichen Yang, Nicholas Konz, and Yixin Zhang. Segment anything model for medical image analysis: An experimental study. *Medical Image Analysis*, 89:102918, 2023. doi: 10.1016/j.media.2023.102918.
- Juzheng Miao, Cheng Chen, Keli Zhang, Jie Chuai, Quanzheng Li, and Pheng-Ann Heng. Cross prompting consistency with segment anything model for semi-supervised medical image segmentation. In *Medical Image Computing and Computer Assisted Intervention*, pages 167–177, 2024. doi: 10.1007/978-3-031-72120-5.16.
- Nima Tajbakhsh, Laura Jeyaseelan, Qian Li, Jeffrey N. Chiang, Zhihao Wu, and Xiaowei Ding. Embracing imperfect datasets: A review of deep learning solutions for medical image segmentation. *Medical Image Analysis*, 63:101693, 2020. doi: 10.1016/j.media.2020.101693.
- Feilong Tang, Zhongxing Xu, Ming Hu, Wenxue Li, Peng Xia, Yiheng Zhong, Hanjun Wu, Jionglong Su, and Zongyuan Ge. Neighbor does matter: Density-aware contrastive learning for medical semi-supervised segmentation. *arXiv preprint arXiv:2412.19871*, 2024.
- Antti Tarvainen and Harri Valpola. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- Vi Vu, Thanh-Huy Nguyen, Tien-Thinh Nguyen, Ba-Thinh Lam, Hoang-Thien Nguyen, Tianyang Wang, Xingjian Li, and Min Xu. From specialist to generalist: Unlocking SAM’s learning potential on unlabeled medical images. *arXiv preprint arXiv:2601.17934*, 2026.
- Mengzhu Wang, Jiao Li, Houcheng Su, Nan Yin, Liang Yang, and Shen Li. GraphCL: Graph-based clustering for semi-supervised medical image segmentation. *arXiv preprint arXiv:2411.13147*, 2024.
- Yicheng Wu, Zongyuan Ge, Donghao Zhang, Minfeng Xu, Lei Zhang, Yong Xia, and Jianfei Cai. Mutual consistency learning for semi-supervised medical image segmentation. *Medical Image Analysis*, 81:102530, 2022. doi: 10.1016/j.media.2022.102530.
- Guoping Xu, Xiaoxue Qian, Hua Chieh Shao, Jax Luo, Weiguo Lu, and You Zhang. A SAM-guided and match-based semi-supervised segmentation framework for medical imaging. *arXiv preprint arXiv:2411.16949*, 2024.
- Chenyu You, Weicheng Dai, Yifei Min, Lawrence Staib, and James S. Duncan. Bootstrapping semi-supervised medical image segmentation with anatomical-aware contrastive distillation. *arXiv preprint arXiv:2206.02307*, 2022.
- Mingen Zhang, Yuanyuan Gu, Meng Wang, Lei Mou, Jingfeng Zhang, and Yitian Zhao. YoloSeg: You only label once for medical image segmentation. *Medical Image Analysis*, 112:104093, 2026. doi: 10.1016/j.media.2026.104093.
- Renrui Zhang, Zhengkai Jiang, Ziyu Guo, Shilin Yan, Juntong Pan, Xianzheng Ma, Hao Dong, Peng Gao, and Hongsheng Li. Personalize segment anything model with one shot. *arXiv preprint arXiv:2305.03048*, 2023.
- Yichi Zhang, Jin Yang, Yuchen Liu, Yuan Cheng, and Yuan Qi. SemiSAM: Enhancing semi-supervised medical image segmentation via SAM-assisted consistency regularization. In *IEEE International Conference on Bioinformatics and Biomedicine*, pages 3982–3986, 2024. doi: 10.1109/BIBM62325.2024.10821951.
- Yichi Zhang, Bohao Lv, Le Xue, Wenbo Zhang, Yuchen Liu, Yu Fu, Yuan Cheng, and Yuan Qi. SemiSAM+: Rethinking semi-supervised medical image segmentation in the era of foundation models. *Medical Image Analysis*, 106:103733, 2025. doi: 10.1016/j.media.2025.103733.

Zerong Zhang and Lianghua He. SAM foundation model and expert model cross prompting framework for semi-supervised medical image segmentation. *Journal of Visual Communication and Image Representation*, 119:104876, 2026. doi: 10.1016/j.jvcir.2026.104876.