

RouteSAM: 通过跨图像语义路径实现半监督二维医学图像分割

作者信息待补充

摘要

医学图像的高昂标注成本使半监督学习成为医学图像分割中的重要研究方向。然而，当有限的标注数据难以充分覆盖多样化的病灶表征时，半监督分割模型往往会出现明显的性能下降。尤其是在标注数据与未标注数据之间存在较大语义差异的情况下，有限的标注信息难以稳定迁移至未标注图像，从而影响所生成伪监督的可靠性。为此，我们提出 RouteSAM，一种基于语义路由的渐进式监督传播方法。为使有限监督覆盖尽可能广泛的特征空间，RouteSAM 首先从训练数据中筛选具有较高特征覆盖性的样本，作为后续监督传播的起点。进一步地，针对未标注图像，RouteSAM 在其与已标注图像之间构建由多个特征相关图像组成的传播路径，使监督信息沿语义邻近的图像逐步传递，从而避免在特征差异较大的图像之间进行困难的直接迁移。在此基础上，我们进一步设计了一种多阶段的通用模型-专用模型协同机制，利用 SAM3 的通用分割能力与任务特定 U-Net 的医学域知识，通过伪监督的迭代筛选与模型间的协同适配，逐步提高监督信息的可靠性并增强模型对目标医学任务的适应能力。在 Kvasir-SEG、BUSI 和 ISIC2018 数据集上的实验结果表明，RouteSAM 在极少量标注数据下能够有效提升半监督医学图像分割性能，[最终定量结果待补充]。

关键词：半监督医学图像分割；sSegment Anything Model；跨图像传播；语义路径；伪标签学习

1 引言

医学图像分割能够对病灶、器官以及其他具有临床意义的解剖结构进行精细的空间勾画，是计算机辅助诊断、疾病定量评估和治疗方案制定等任务的重要基础。近年来，深度学习显著提升了医学图像分割的性能，但高性能分割模型通常需要大量高质量的像素级标注。相比自然图像，医学图像的精确标注往往需要医务人员投入较多时间并具备相应的专业知识，因此大规模医学图像标注数据的获取成本较高且难度较大 Hesamian et al. (2019); Tajbakhsh et al. (2020)。为降低对人工标注的依赖，半监督医学图像分割 (Semi-Supervised Medical Image Segmentation, SSMIS) 通过联合利用少量有标注数据和大量无标注数据，逐渐成为医学图像分割中的重要研究方向 Jiao et al. (2024)。

现有 SSMIS 方法主要通过伪标签学习与一致性正则化从无标注数据中获取额外监督。一类方法根据模型预测构造伪标签，并通过教师-学生结构或多个网络之间的协同学习不断更新监督信息；另一类方法则对输入、特征表示或模型自身施加扰动，并约束模型在不同扰动条件下保持预测一致。Cross Teaching、MC-

Net+ 和 BCP 等代表性方法分别通过异构网络之间的相互监督、不确定性感知的一致性学习，以及有标注与无标注样本之间的双向混合，提高了无标注数据的利用效率 Luo et al. (2022); Wu et al. (2022); Bai et al. (2023)。然而，当人工标注样本进一步减少时，模型从有标注数据中能够学习到的可靠任务知识也会相应下降，由模型自身产生的伪标签因而更容易受到预测错误和不确定性的影响。

可提示分割基础模型的出现，为获取更强的监督信息带来了新的机会。Segment Anything Model (SAM) 及其后续模型通过大规模预训练获得了通用视觉表征能力和提示驱动的分割先验，可以根据点、框或掩码等提示对目标区域进行分割 Kirillov et al. (2023)。尽管自然图像与医学图像之间存在明显的领域差异，使 SAM 在不同医学影像任务上的直接分割表现并不稳定 Mazurowski et al. (2023); Ma et al. (2024)，其通过大规模预训练获得的通用分割知识仍具有较高的利用价值。因此，近年来已有研究开始将 SAM 引入半监督医学图像分割：利用任务特定模型生成提示，并通过 SAM 的预测结果构造或改善无标注数据上的伪监督。例如，SemiSAM 使用任务特定分割模型为 SAM 提供定位提示；SemiSAM+ 进一步建立了通用基础模型与任务特定专用模型之间的协作关系；SAMatch 则借助 SAM 对已有预测结果进行进一步优化 Zhang et al. (2024, 2025); Xu et al. (2024)。这些研究说明，基础模型中包含的通用分割先验可以成为无标注医学图像学习中的另一种监督来源。然而，现有方法大多仍将重点放在提升每一幅无标注图像自身的预测结果或伪标签质量上，尚未充分利用训练样本之间的跨样本语义关系。

值得注意的是，医学图像之间并非彼此独立，同类解剖结构或病灶在不同样本中往往存在可关联的语义模式。已有研究表明，不同医学图像之间存在可以利用的跨样本语义关系。例如，ACTION 同时建模全局语义关系和局部解剖信息，以提升半监督表示学习效果，这说明训练样本之间并不一定需要被视为彼此完全独立的实例 You et al. (2022)。进一步地，YoloSeg 使用 SAM2 将单个已标注图像中的分割信息传播到无标注图像，展示了跨图像传播在极低标注环境中的潜力 Zhang et al. (2026)。然而，这类传播方式仍主要采用从有标注图像直接到目标图像的单跳传播形式。当两幅图像在病灶形态、尺度或外观方面存在较大的语义差异时，直接传播需要在一步之内跨越较大的图像间差异，因而容易产生不稳定的伪监督。这进一步引出了一个问题：是否可以利用无标注数据内部的样本关系，在已有监督与困难目标之间加入若干语义相关的中间图像，从而把一次较困难的直接传播拆解为若干更加局部的传播步骤？

围绕这一问题，我们进一步研究如何利用无标注

数据内部的关系来组织有限监督的传播过程。我们将无标注训练集视为由样本间语义关系构成的潜在空间，并提出 **RouteSeg**。在固定的标注预算下，RouteSeg 首先从训练集中选择能够较广泛覆盖训练数据分布的已标注样本，并将其定义为 **Anchor**。对于每一个需要生成伪标签的无标注 **Target**，RouteSeg 从无标注数据中检索若干与之具有语义关联的图像作为 **Bridge**，再依据图像之间的跨样本关系将其排列成一条有序的语义路径 (*semantic route*):

$$A \rightarrow B_1 \rightarrow B_2 \rightarrow \dots \rightarrow B_K \rightarrow T. \quad (1)$$

随后，RouteSeg 基于 SAM3 沿这条语义路径执行渐进式跨图像传播 (*progressive cross-image propagation*)，逐步将 Anchor 中提供的分割信息传播到 Target。相较于直接传播，Bridge 的加入能够将一次跨度较大的图像间变化拆分为多个更加局部的传播过程。这样，无标注样本不再只是等待生成伪标签的 Target，它还可以在其他 Target 的语义路径中充当 Bridge，从而参与有限监督的扩展过程。由于不同的 Anchor 和语义路径可能针对同一个 Target 生成不同的掩码候选，因此直接使用全部传播结果可能会引入不可靠的伪监督。为此，RouteSeg 进一步对这些掩码候选进行质量评估，并选取可靠的路由伪标签 (*route-derived pseudo-labels*) 用于后续训练。被选中的伪标签与 Anchor 的真实标注共同用于训练任务特定的分割模型，该模型被称为 **specialist**；SAM3 则作为 **generalist**。Specialist 从目标医学数据中学习任务特定知识，并进一步对 generalist 的传播结果提供反馈，使基础模型的通用分割先验与医学任务中的领域知识形成互补。语义路由和跨图像传播只在训练阶段使用；在推理阶段，specialist 可以直接对单幅图像完成分割，不需要检索 Anchor、构建语义路径，也不需要额外的人工提示。

我们在 Kvasir-SEG、BUSI 和 ISIC2018 三个具有不同成像特点与病灶类型的二维医学图像分割数据集上评估 RouteSeg，并统一采用约 1% 的标注预算。实验将 RouteSeg 与具有代表性的半监督医学图像分割方法、SAM 辅助的低标注分割方法以及直接跨图像传播策略进行比较，从而考察跨图像监督路由 (*cross-image supervision routing*) 对于扩展有限监督的作用。此外，我们还针对 Anchor 选择、Bridge 的引入和语义路径构建等关键组成部分开展消融与分析，以研究不同路由设计如何影响伪监督质量和最终的分割性能。

本文的主要贡献概括如下：

- 我们提出 RouteSeg，一种面向极低标注半监督医学图像分割的跨图像监督路由框架。通过将无标注训练集视为由样本间语义关系构成的潜在空间，RouteSeg 使有限监督能够沿语义路径逐步传播。
- 我们提出 Coverage-Aware Anchor Selection 与 Anchor-Bridge-Target 语义路由机制。前者在固定标注预算下选择具有代表性的已标注样本作为 Anchor，后者检索语义相关的无标注 Bridge，并基于 SAM3 执行渐进式跨图像传播，将困难的直接传播拆分为多个局部步骤。
- 我们提出可靠的路由伪监督学习与 generalist-

specialist 协同策略，从不同语义路径产生的掩码候选中筛选可靠伪标签，并利用 specialist 学习到的任务特定知识进一步改善 generalist 的传播结果。

2 相关工作

2.1 半监督医学图像分割

半监督医学图像分割旨在利用少量像素级标注和大量未标注图像降低医学分割的标注成本。现有方法主要围绕如何从未标注数据中获得可靠监督展开。一类代表性方法通过一致性约束或伪标签学习利用未标注样本。Mean Teacher 使用学生模型参数的指数滑动平均构建教师模型，并约束不同扰动下的预测一致性 Tarvainen and Valpola (2017)；Cross Pseudo Supervision 通过两个独立初始化的网络相互生成伪标签 Chen et al. (2021)；Cross Teaching 进一步利用 CNN 与 Transformer 不同的归纳偏置进行交叉监督 Luo et al. (2022)；MC-Net+ 则通过多个具有差异性的解码器建模预测不确定性，并利用相互一致性约束未标注数据 Wu et al. (2022)。这些方法逐步从单一教师监督扩展到多模型或异构模型之间的互补监督，其核心仍是从模型自身对未标注图像的预测中构造训练信号。

在此基础上，后续研究进一步关注伪监督的可靠性以及标注数据与未标注数据之间的有效交互。BCP 通过双向 Copy-Paste 在标注样本和未标注样本之间进行区域混合，以减小两类数据之间的经验分布差异 Bai et al. (2023)；ABD 根据预测置信度执行自适应的双向区域置换，以控制扰动过程中引入的伪标签噪声 Chi et al. (2024)；DyCON 则结合动态不确定性感知的一致性学习与对比学习，对不同可靠程度的未标注区域进行差异化优化 Assefa et al. (2025)。总体而言，这类方法主要从预测一致性、伪标签质量、数据扰动或局部样本交互的角度提升未标注数据的利用效率。相比之下，本文关注的并不是如何进一步改进单个未标注样本上的预测约束，而是如何利用未标注数据之间的语义关系，显式组织稀疏分割监督在多张图像之间的传播过程。

2.2 基础模型辅助的少标注医学图像分割

随着 Segment Anything Model (SAM) 等通用分割基础模型的发展，大规模预训练获得的分割先验开始被用于提升少标注医学图像分割中的监督质量。SemiSAM 在传统半监督框架中引入冻结的 SAM 辅助分支，由任务模型根据未标注图像的预测生成提示，并利用 SAM 输出提供额外的一致性监督 Zhang et al. (2024)。SemiSAM+ 进一步将这一思路扩展为通用模型与任务模型之间的协同学习，通过置信度感知机制利用一个或多个冻结的基础模型增强未标注数据上的监督信号 Zhang et al. (2025)。SAMatch 则将弱到强的一致性学习与经过任务适配的 SAM 相结合，由教师模型自动产生提示，再通过 SAM 获得更完整的伪标签用于学生模型训练 Xu et al. (2024)。这类方法的共同思路是利用基础模型已有的分割先验，对任务模型产生的定位信息或初始预测进行补充和修正，从而提高单个未

标注样本上的伪监督质量。

进一步的研究开始关注基础模型与任务模型之间更充分的双向知识交互。CPC-SAM 通过不同 SAM 解码分支之间的交叉提示与一致性约束增强未标注样本学习 Miao et al. (2024); SC-SAM 使用任务专用 U-Net 为 SAM 提供点提示和伪标签以进行参数高效适配, 同时利用 SAM 的预测反向约束任务模型 Vu et al. (2026); CPPS-SAM 则通过交叉提示和交叉伪监督, 在 CNN 专家模型与 SAM 通用模型之间实现双向知识传递 Zhang and He (2026)。这些工作表明, 通用分割先验与任务特定知识之间的互补能够有效改善少标注条件下的监督学习。然而, 现有协同机制主要围绕同一未标注图像上的提示生成、预测修正和模型交互展开, 尚未进一步利用不同未标注图像之间的语义联系来组织监督的跨图像传播。RouteSeg 则从这一角度出发, 将基础模型的作用由单图伪标签增强进一步扩展到跨图像监督传播过程。

2.3 跨图像关系建模与监督传播

除单图像上的一致性学习与伪标签优化外, 一些研究开始显式利用不同样本之间的关系来增强半监督表示学习。ACTION 通过全局语义关系与局部解剖对比进行知识蒸馏, 以利用数据集内部的跨样本结构 You et al. (2022); DACL 构建密度感知的邻域关系, 将稀疏区域特征向高密度类别区域聚合 Tang et al. (2024); GraphCL 则通过实例图与图聚类对不同样本间的结构信息进行建模 Wang et al. (2024)。这些工作说明未标注医学图像之间并非相互独立, 其潜在的邻域关系和语义结构能够为模型学习提供额外信息。然而, 这类方法主要将跨样本关系用于特征约束、对比学习或聚类优化, 并未直接将这种关系转化为分割监督在图像之间的传播过程。

另一类与本文更为接近的方法直接利用参考图像或已标注样本向目标图像传递分割信息。PerSAM 根据单个参考图像及其掩码对 SAM 进行个性化, 使其能够在目标图像中识别对应对象 Zhang et al. (2023); Matcher 通过通用视觉特征匹配实现 one-shot 条件下的目标区域迁移 Liu et al. (2023); OP-SAM 利用支持图像与查询图像之间的特征相关性和迭代提示, 将单个标注样本中的息肉先验传递到目标图像 Mao et al. (2025)。进一步地, YoloSeg 使用 SAM2 的传播能力将单个标注样本扩展到未标注数据, 并通过多视图共识与差异区域学习抑制传播噪声, 最终训练任务专用分割模型 Zhang et al. (2026)。这些方法证明了利用基础模型进行跨图像监督迁移的可行性, 但其传播过程主要围绕标注源与目标图像之间的直接对应关系展开。

RouteSeg 进一步关注在标注源与困难目标之间是否存在可用于过渡的未标注样本。与直接从单个支持样本向目标传递监督不同, RouteSeg 将未标注数据集视为一个由样本间语义关系构成的潜在传播空间, 并主动选择和排序中间图像, 使监督能够沿由 Anchor、Bridge 和 Target 组成的有序路径逐步传递。由此, 未标注图像不再仅作为等待生成伪标签的目标样本, 而是同时作为连接稀疏标注与困难目标的中间语义节点。

3 方法

3.1 问题定义与整体框架

半监督医学图像分割旨在利用少量具有像素级标注的图像与大量未标注图像共同训练分割模型。设训练集为

$$\mathcal{D}_{tr} = \mathcal{D}_L \cup \mathcal{D}_U, \quad (2)$$

其中

$$\mathcal{D}_L = \{(x_i, y_i)\}_{i=1}^K \quad (3)$$

表示具有人工分割标注的样本集合,

$$\mathcal{D}_U = \{x_j\}_{j=1}^{N-K} \quad (4)$$

表示其余未标注训练图像。本文主要关注极低标注条件, 即仅有约 1% 的训练图像能够提供可靠的像素级监督。在这种情况下, 少量有标注样本往往只能覆盖有限的病灶形态、尺度和成像外观。当未标注图像与现有有标注样本之间存在较大的视觉或语义差异时, 无论是由任务分割网络直接生成伪标签, 还是利用可提示分割基础模型进行跨图像迁移, 都容易产生不完整、偏移或形态失真的分割结果。更重要的是, 一旦这些低质量预测被重新作为训练监督, 其误差还可能在后续学习过程中被进一步强化。因此, 极低标注条件下的关键问题不仅在于如何为未标注图像产生预测, 更在于如何使有限而可靠的监督能够稳定地覆盖更广泛的训练数据分布。

针对这一问题, 我们不再将每一幅未标注图像视为彼此独立的伪标签生成目标, 而是利用训练数据内部存在的跨图像语义连续性, 显式规划监督信息从已有标注样本向未标注样本传播的路径。其核心思想是: 当某一待处理图像与有标注样本之间差异较大时, 不强制监督一次性完成跨越较大语义距离的直接迁移, 而是在训练集中寻找若干与二者逐步相关的图像作为中间状态, 将一次困难的跨图像迁移分解为多个更局部的传播步骤。由此, 未标注图像不仅是等待获得伪标签的训练样本, 也可以作为连接有限人工监督与困难样本的语义过渡节点。在此基础上, RouteSAM 利用 SAM3 的跨帧目标传播能力, 将经过语义排序的独立医学图像组织为短伪视频, 使分割信息能够沿所构建的语义路径逐步传播; 随后再利用任务特定分割模型学习这些扩展后的伪监督, 并对传播结果提供医学任务域的补充约束。

整体而言, RouteSAM 主要由四个相互衔接的组成部分构成。首先, 为使极少量人工监督尽可能覆盖训练数据中的不同视觉模式, 我们从训练集中自动选择一组具有较好分布代表性的样本作为监督传播的起始样本。其次, 针对每一幅待处理图像, 根据其与其他监督起始样本及训练图像之间的语义关系, 在未标注数据中搜索适合作为中间状态的图像, 并将其组织为从监督起始样本逐步到达待处理图像的有序语义路径。随后, 将该路径中的图像按照既定顺序组织为短伪视频, 并利用 SAM3 的跨帧目标传播能力, 使分割信息沿语义路径逐步传递至待处理图像, 从而生成相应的伪监督。最后, 将人工标注与跨图像传播得到的伪监督用于后续半监督分割学习, 使扩展后的监督信息能够被任务特定模型进一步吸收和利用。语义检索、路径构

建与 SAM3 跨图像传播主要服务于训练阶段的监督扩展, 而最终分割模型在测试阶段直接处理单幅医学图像, 无需重新执行监督起始样本检索、语义路由或跨图像传播。

3.2 覆盖感知的监督起始样本自动选择

在极低标注条件下, 监督起始样本的数量十分有限, 其分布直接影响后续监督传播能够覆盖的训练数据范围。当这些样本集中在训练数据分布的局部区域时, 部分未标注图像与已有监督之间会存在较大的语义差异, 增加跨图像传播过程中的误差累积。针对这一问题, 我们在人工标注之前首先从训练集中选择一组具有较好分布代表性的样本, 使有限监督尽可能覆盖不同的病灶形态、尺度和成像外观, 并将其作为后续语义路由的监督起点。

具体而言, 我们使用冻结的 SAM3 视觉编码器提取每幅训练图像的局部特征。SAM3 输出的特征图包含密集的空间 token, 相邻位置之间具有较高冗余, 因此我们在特征图上均匀采样 64 个位置, 并对相应的局部 token 进行 L_2 归一化。这样既保留了图像不同区域的局部信息, 也避免直接使用全部密集特征带来的冗余。

随后, 将所有训练图像中采样得到的局部特征汇总, 并使用 MiniBatch K-Means 构建包含 $M = 64$ 个视觉词的共享词典。每个局部特征被分配到距离最近的视觉词, 并据此统计每幅图像的视觉词频率。由于部分视觉词可能在大量图像中反复出现, 我们采用 TF-IDF 降低这类共有模式的权重。对于图像 x_i 中第 m 个视觉词, 其归一化权重定义为

$$p_{im} = \frac{\text{tf}_{im} \text{idf}_m}{\sum_{l=1}^M \text{tf}_{il} \text{idf}_l}, \quad \text{idf}_m = \log \frac{N+1}{\text{df}_m+1} + 1, \quad (5)$$

其中, N 为训练图像数量, tf_{im} 表示第 m 个视觉词在图像 x_i 中的出现频率, df_m 表示包含该视觉词的训练图像数量。由此得到图像级视觉词分布 $\mathbf{p}_i = (p_{i1}, p_{i2}, \dots, p_{iM})$ 。

基于视觉词分布, 我们使用 Hellinger 映射后的分布相似度比较不同训练图像:

$$k(i, j) = \sum_{m=1}^M \sqrt{p_{im} p_{jm}}. \quad (6)$$

其中, $k(i, j)$ 越大, 表示图像 x_i 与 x_j 的局部视觉模式组成越接近。该度量等价于视觉词分布之间的 Bhattacharyya 系数, 使图像间关系由高维局部特征的直接比较转化为局部模式分布的比较。

在此基础上, 我们选择一组能够尽可能代表整个训练集的监督起始样本。设所选样本集合为 $\mathcal{A}$, 对于任意训练图像 x_i , 其与集合 $\mathcal{A}$ 中最相近样本的相似度表示该图像被当前集合覆盖的程度。于是定义

$$F(\mathcal{A}) = \frac{1}{N} \sum_{i=1}^N \max_{a \in \mathcal{A}} k(i, a). \quad (7)$$

我们通过贪心搜索逐步加入能够最大程度提升 $F(\mathcal{A})$ 的样本, 直至达到预设的标注数量。最终选出的样本构成监督起始样本集合, 并在后续语义路由和 SAM3 跨图像传播中提供初始监督。

3.3 面向待处理图像的语义路由构建

尽管上一节选择的监督起始样本能够较好地覆盖训练数据分布, 但对于具体的待处理图像而言, 其病灶形态、尺度或成像外观仍可能与现有监督起始样本存在较大差异。若直接在两者之间传递分割信息, 较大的图像差异容易影响后续传播的稳定性。为此, 我们不直接连接监督起始样本与待处理图像, 而是在训练集中寻找若干语义中间图像, 将一次跨度较大的跨图像迁移分解为多个相对平缓的过渡过程。对于待处理图像 t , 最终需要构建一条有序路径

$$r = (a, x_1, x_2, \dots, x_6, t), \quad (8)$$

其中, a 表示监督起始样本, $x_1, \dots, x_6$ 表示从训练集中选择的语义中间图像。该路径只决定后续监督传播所经过的图像及其顺序。

构建这一路径的第一个问题是, 如何判断一幅训练图像是否适合出现在从某个监督起始样本出发的路径中。由于监督起始样本已经具有人工作出的分割标注, 我们可以利用该标注明确图像中需要向后传递的区域。具体而言, 在 256×256 分辨率下使用冻结的 SAM3 视觉编码器提取局部特征, 并将监督起始样本 a 的分割标注映射到对应的特征网格。设标注区域覆盖的特征位置集合为 Ω_a , 则对这些位置上的局部特征进行平均并归一化, 得到

$$\mathbf{u}_a = \text{norm} \left(\frac{1}{|\Omega_a|} \sum_{p \in \Omega_a} \mathbf{z}_{ap} \right), \quad (9)$$

其中, $\mathbf{z}_{ap}$ 表示监督起始样本 a 在位置 p 处的局部特征, $\text{norm}(\cdot)$ 表示 L_2 归一化。 $\mathbf{u}_a$ 概括了监督起始样本中已标注区域的特征, 可用于在其他训练图像中判断是否存在与该区域相近的局部内容。

对于任意训练图像 x_i , 同样提取其局部特征, 并比较这些局部特征与 $\mathbf{u}_a$ 的相似程度。与 $\mathbf{u}_a$ 更接近的局部区域在特征聚合时获得更高权重, 由此得到针对监督起始样本 a 的图像表示 $\mathbf{h}_{a,i}$ 。我们进一步以

$$s(a, i) = \mathbf{h}_{a,i}^T \mathbf{u}_a \quad (10)$$

衡量图像 x_i 与监督起始样本中已标注区域的相关程度。较大的 $s(a, i)$ 表明图像 x_i 中包含更多与该已标注区域相近的局部特征, 因此更适合作为从监督起始样本 a 出发的路径候选。考虑到不同监督起始样本产生的相关性分数可能具有不同的整体取值水平, 我们利用训练集 RGB 图像计算每个监督起始样本的平均分数, 并对其进行中心化:

$$\tilde{s}(a, i) = s(a, i) - \frac{1}{|\mathcal{D}_{\text{tr}}|} \sum_{x_j \in \mathcal{D}_{\text{tr}}} s(a, j), \quad (11)$$

其中, $\mathcal{D}_{\text{tr}}$ 表示训练图像集合。经过这一校准后, 不同监督起始样本对应的相关性分数可以在较为一致的尺度上进行比较。

仅依赖上述相关性仍不足以形成适合传播的路径。两幅图像可能都包含与监督起始样本已标注区域相近的局部特征, 但二者在整体结构和成像外观上仍可能存在较大差异。如果这样的图像被连续排列在路径中,

仍会形成明显的跨图像跳变。因此,在选择语义中间图像时,我们同时考虑相邻图像之间的整体视觉相似度。具体而言,对每幅图像的局部特征进行平均和归一化得到整体描述子,并通过余弦相似度衡量相邻图像之间的接近程度。这样,路径中的每个图像既需要与监督起始样本中已标注区域保持足够的相关性,又需要与前后相邻图像保持较为平缓的视觉变化。

基于上述两种关系,我们进一步评价整条候选路径。对于路径 r ,将路径中各图像与监督起始样本之间的相关性以及相邻图像之间的视觉相似度汇总为集合 $V(r)$ 。由于一次明显的低相似度跳跃就可能破坏后续传播,我们优先关注整条路径中最弱的一环,并在此基础上考虑整体平均质量:

$$Q(r) = \left(\min_{v \in V(r)} v, \frac{1}{|V(r)|} \sum_{v \in V(r)} v \right). \quad (12)$$

不同候选路径按照 $Q(r)$ 进行字典序比较,即优先选择最小值更大的路径;当最小值相同时,再选择平均值更大的路径。这样可以避免少数高相似度图像掩盖路径中某一次明显的语义跳变。

由于直接枚举所有可能的中间图像组合会带来较大的计算开销,我们采用 beam search 逐步扩展候选路径,并在每一步保留 32 条得分较高的路径。监督起始样本、语义中间图像和待处理图像在同一路径中不重复,所有语义中间图像均来自训练集。最终,选择得分最高的路径

$$r_t^* = (a^*, x_1^*, \dots, x_6^*, t) \quad (13)$$

作为待处理图像 t 的语义路由。该有序图像序列随后用于承载监督信息从起始样本向待处理图像的逐步传播。

3.4 基于 SAM3 的渐进式跨图像传播

经过语义路由构建后,每幅待处理图像 t 都对应一条从监督起始样本出发的有序图像路径

$$r_t^* = (a^*, x_1^*, x_2^*, \dots, x_6^*, t). \quad (14)$$

路径中的图像虽然来自彼此独立的医学图像,但其排列顺序已经由上一节的语义关系确定。我们据此将这些图像组织为一个伪视频序列,使 SAM3 可以利用其视频传播能力,将监督起始样本中的分割信息沿语义路径逐步传递至待处理图像。

对于路径中的监督起始样本 a^* ,我们利用其人工分割标注生成包围目标区域的紧致边界框,并将该边界框作为伪视频首帧的初始提示。除首帧外,其余语义中间图像以及待处理图像均不提供额外的人工 mask、边界框或文本提示。因此,后续帧的分割完全依赖 SAM3 对首帧监督信息的连续传播,而不会引入新的人工标注。

具体地,将路径中的所有图像统一调整为 256×256 ,并按照

$$[I_{a^*}, I_{x_1^*}, \dots, I_{x_6^*}, I_t] \quad (15)$$

的顺序输入冻结的 SAM3。模型首先根据监督起始样本上的边界框建立目标状态,随后沿语义路由依次处

理各中间图像,并将前序帧积累的目标信息持续传递至后续帧。由于相邻图像在路由阶段已经受到视觉连续性的约束,监督信息无需直接跨越监督起始样本与待处理图像之间可能存在的较大差异,而是通过多个语义相近的中间图像逐步完成迁移。

当传播到序列最后一帧时, SAM3 在待处理图像 t 上输出预测分割结果,并将其记为

$$\widehat{M}_t^{(1)} = \text{SAM3Propagate}(r_t^*). \quad (16)$$

$\widehat{M}_t^{(1)}$ 即由有限人工监督经语义路由传播得到的初始伪监督。通过对未标注训练图像重复上述过程,可以将少量监督起始样本上的人工标注扩展到更广泛的训练数据,为后续半监督学习提供初始伪标签。

3.5 基于传播可靠性的加权半监督学习

经过前述语义路由与跨图像传播后,每幅未标注训练图像均可以获得一个由固定六桥路径生成的伪分割结果。然而,不同图像上的传播难度并不一致,直接将所有伪标签以相同强度用于训练,容易使传播过程中产生的错误被进一步学习。另一方面,仅保留少量高置信伪标签又会显著减少可利用的未标注数据。基于这一考虑,我们不重新选择或融合不同传播路线产生的 mask,而是始终保留固定六桥传播得到的伪标签,并根据传播过程本身的一致性为不同图像分配不同的监督权重。

对于未标注图像 t ,记由包含 b 幅语义中间图像的传播路线得到的候选 mask 为

$$C_t^{(b)}, \quad b \in \{0, 1, \dots, 6\}. \quad (17)$$

其中, $C_t^{(6)}$ 为上一节固定六桥传播得到的伪标签,也是后续 U-Net 训练中实际使用的监督目标:

$$\widehat{Y}_t = C_t^{(6)}. \quad (18)$$

其余六个候选仅用于估计传播结果的可靠程度,不参与投票、融合或伪标签重构。

返回一致性. 首先,我们从传播路径本身的可逆性判断固定六桥结果是否可靠。对于由监督起始样本 a 到待处理图像 t 的六桥路径, SAM3 首先按照正向顺序传播,并在图像 t 上得到 $C_t^{(6)}$ 。随后,以该预测结果重新初始化传播状态,并沿同一路径反向传播至原始监督起始样本,得到返回结果 $R_t^{(6)}$ 。由于监督起始样本具有人工标注 G_a ,可以直接比较返回结果能否恢复最初的已知目标:

$$q_{\text{return}}(t) = \text{Dice}(R_t^{(6)}, G_a). \quad (19)$$

这里的 $q_{\text{return}}(t)$ 并不评价待处理图像上的预测是否与未知真值一致,而是衡量一次“监督起始样本 $\rightarrow$ 待处理图像 $\rightarrow$ 监督起始样本”的闭环传播是否稳定。较高的返回一致性意味着分割信息经过整条路径传播后仍能够较好地恢复已知的起始区域,因此我们将其作为识别高可靠传播样本的依据。

具体而言,将全部未标注训练图像按照 q_{return} 从高到低排序,并将前 30% 的样本记为高返回一致性集

合 $\mathcal{H}$ 。这些样本在后续训练中直接采用完整的伪监督权重。需要强调的是，返回一致性仅用于区分这一高可靠样本集合，而不直接作为连续损失权重。

多路线一致性。 对于其余样本，我们进一步利用同一图像在不同传播路线下预测结果之间的一致程度估计伪标签可靠性。对于图像 t 的七个候选 $\{C_t^{(0)}, \dots, C_t^{(6)}\}$ ，计算所有候选两两之间的 Dice，并取平均：

$$q_{\text{multi}}(t) = \frac{1}{21} \sum_{0 \leq i < j \leq 6} \text{Dice}(C_t^{(i)}, C_t^{(j)}). \quad (20)$$

当不同传播路径得到的分割结果较为接近时， $q_{\text{multi}}(t)$ 较高；反之，如果候选结果随传播路径变化明显，则该分数较低。该分数描述的是多条传播路线之间的预测稳定性，而不是待处理图像上的真实分割精度。

结合上述两种一致性，我们为每幅未标注图像定义图像级伪监督权重

$$w_t = \begin{cases} 1, & t \in \mathcal{H}, \\ 0, & t \notin \mathcal{H} \text{ 且 } C_t^{(6)} = \emptyset, \\ q_{\text{multi}}(t), & \text{其他情况}. \end{cases} \quad (21)$$

因此，高返回一致性样本被完整使用；其余具有非空六桥伪标签的样本根据多路线一致性连续调整监督强度；对于固定六桥传播为空的样本，则不提供伪监督梯度。整个过程仅在图像级调整权重，不进一步引入像素级置信度。

在获得加权伪标签后，我们训练一个任务特定的 U-Net，将少量人工标注数据与未标注数据共同用于优化。每个训练批次同时采样有标注样本和伪标注样本，其中有标注图像采用较弱的增强，伪标注图像采用更强的增强。对于人工标注样本，监督损失由交叉熵和 soft Dice loss 组成：

$$\mathcal{L}_{\text{GT}} = \mathcal{L}_{\text{CE}}^{\text{GT}} + \mathcal{L}_{\text{Dice}}^{\text{GT}}. \quad (22)$$

对于当前伪标注 mini-batch 中的图像 t ，分别计算其交叉熵损失 $\mathcal{L}_{\text{CE}}^t$ 和 Dice 损失 $\mathcal{L}_{\text{Dice}}^t$ ，并使用图像级可靠性权重同时调节二者：

$$\mathcal{L}_{\text{pseudo}} = \frac{1}{B_u} \sum_{t=1}^{B_u} w_t (\mathcal{L}_{\text{CE}}^t + \mathcal{L}_{\text{Dice}}^t), \quad (23)$$

其中， B_u 表示每个 batch 中伪标注样本的数量。对于预测前景概率 $P_t(p)$ 和二值伪标签 $\hat{Y}_t(p)$ ，Dice 损失定义为

$$\mathcal{L}_{\text{Dice}}^t = 1 - \frac{2 \sum_p P_t(p) \hat{Y}_t(p) + 1}{\sum_p P_t(p) + \sum_p \hat{Y}_t(p) + 1}. \quad (24)$$

最终训练目标写为

$$\mathcal{L}(k) = \mathcal{L}_{\text{GT}} + \lambda(k) \mathcal{L}_{\text{pseudo}}, \quad (25)$$

其中，伪监督系数在训练初期逐渐增加：

$$\lambda(k) = 0.5 \min \left(1, \frac{k}{2000} \right), \quad (26)$$

k 表示当前训练步数。该渐进式权重使模型首先依赖可靠的人工监督建立基本分割能力，再逐步增加伪标注数据对参数更新的影响。

通过上述训练方式，固定六桥传播得到的伪标签始终保持不变，而传播过程中产生的返回一致性和多路线一致性仅用于调节不同伪标签对模型训练的贡献。这样既保留了全部未标注训练图像所提供的覆盖，又降低了低可靠传播结果在半监督训练中的影响。

3.6 问题定义与整体框架

半监督医学图像分割的目标是在少量像素级标注和大量未标注图像的条件下训练分割模型。设训练集为

$$D_{\text{tr}} = \{x_i\}_{i=1}^N, \quad (27)$$

其中有标注集合和未标注集合分别记为

$$D_L = \{(x_a, y_a)\}_{a=1}^K, \quad D_U = \{x_t\}_{t=1}^{N-K}. \quad (28)$$

在极低标注条件下， D_L 难以覆盖 D_U 中多样的病灶形态、尺度与成像特征，部分未标注图像 x_t 与所有有标注图像 x_a 的语义距离都较大。此时，直接跨图像传播 $x_a \rightarrow x_t$ 需要在一步之内跨越较大的图像间差异，容易产生偏移、缺失或形态失真的伪监督。

为此，RouteSAM 在 x_a 与 x_t 之间引入若干语义相关的中间图像，并将其称为 Bridge。这些 Bridge 取自未标注集合 D_U ，记为 $x_{b_1}, x_{b_2}, \dots, x_{b_L}$ 。由此构建有序语义路径：

$$x_a \rightarrow x_{b_1} \rightarrow x_{b_2} \rightarrow \dots \rightarrow x_{b_L} \rightarrow x_t. \quad (29)$$

通过这种方式，一次较困难的直接传播被分解为多个相邻样本之间的渐进传播过程。

RouteSAM 的整体框架如图 1 所示，包含四个步骤：覆盖感知的监督起点选择（第 3.9 节）、面向待处理图像的语义路由构建（第 3.10 节）、基于 SAM3 的渐进式跨图像传播（第 3.11 节），以及路由伪监督训练与推理（第 3.12 节）。前三个步骤仅在训练阶段用于扩展有限人工监督；测试时，训练完成的分割网络直接接收单幅图像并输出结果，不再需要参考图像、语义路径或额外人工提示。

3.7 覆盖感知的监督起点选择

在极低标注条件下，监督起点的分布会直接影响后续传播的可靠性。如果少量有标注样本集中在相似的病灶外观或局部数据区域，那么一些与它们差异较大的未标注图像，就只能从语义距离较远的起点开始传播。此时，起点与待处理图像之间需要跨越较大的语义差异，传播过程更容易产生偏移或失真的伪监督。为此，本节在固定标注预算 K 下，从训练集中选择一组能够共同表征主要图像外观模式的样本作为监督起点，记为 $\mathcal{A}$ ，其中 $|\mathcal{A}| = K$ 。选择过程仅依赖训练图像本身，不依赖任何分割掩码。

为衡量不同训练图像所包含局部视觉模式的相似程度，我们利用冻结的 SAM3 视觉骨干提取局部表征，并将其转换为图像级视觉词分布。具体而言，将图像




图 1: RouteSAM 的整体框架。给定极少量人工标注, RouteSAM 首先通过覆盖感知选择确定监督起点; 随后为每幅未标注图像构建由 Anchor、Bridge 和 Target 组成的有序语义路径; 再沿该路径执行基于 SAM3 的渐进式跨图像传播, 生成路由伪标签; 最终, 人工标注与路由伪标签共同用于训练任务特定分割网络。前三个步骤仅在训练阶段使用; 推理阶段仅使用训练完成的 U-Net, 不再依赖 SAM3 或语义路径。

缩放至 1008×1008 , 输入 SAM3 图像编码器, 得到 $72 \times 72 \times 1024$ 的特征图。沿两个空间方向均匀选取 8×8 个位置, 得到 64 个局部 token, 并进行 L_2 归一化。随后, 汇总所有采样 token, 采用 MiniBatch K-Means 学习包含 $M = 64$ 个聚类中心的共享视觉词典。每个 token 被分配到最近聚类中心, 从而统计每幅图像中不同视觉词的出现频率。为降低普遍存在的高频模式影响, 我们进一步统计逆文档频率, 并对词频进行加权与归一化, 得到每幅图像的视觉词概率分布

$$\mathbf{p}_i = (p_{i1}, p_{i2}, \dots, p_{iM}). \quad (30)$$

该表示反映不同局部视觉模式在整幅图像中的组成关系, 不依赖病灶掩码。

在此基础上, 采用 Hellinger 映射将分布变换为单位球面上的向量, 并定义两幅图像 x_i 与 x_j 的相似度为

$$k(i, j) = \sum_{m=1}^M \sqrt{p_{im} p_{jm}}. \quad (31)$$

该相似度即两个视觉词分布之间的 Bhattacharyya 系数。

为选择 K 幅能够共同覆盖训练数据主要视觉模式的图像, 我们采用 facility-location 形式的集合覆盖目标:

$$F(\mathcal{A}) = \frac{1}{N} \sum_{i=1}^N \max_{a \in \mathcal{A}} k(i, a). \quad (32)$$

在固定基数约束 $|\mathcal{A}| = K$ 下, 采用贪心策略逐步选择边际增益最大的图像:

$$a_t = \arg \max_{j \notin \mathcal{A}_{t-1}} [F(\mathcal{A}_{t-1} \cup \{j\}) - F(\mathcal{A}_{t-1})]. \quad (33)$$

由于相似度非负, $F(\mathcal{A})$ 构成单调次模目标, 贪心选择具有 $1 - 1/e$ 近似保证。

经过上述过程得到的监督起点集合 $\mathcal{A}$ 将作为第 3.10 节语义路由的起点。对于每一幅待处理图像, RouteSAM 将从 $\mathcal{A}$ 中为其选择合适的传播起点, 并进一步在 D_U 中检索 Bridge, 构建有序语义路径。

3.8 覆盖感知的监督起点选择

如第 3.6 节所述, 极低标注条件下 D_L 难以覆盖 D_U 中多样的病灶形态与成像特征, 部分未标注图像与所有有标注图像的语义距离都较大。为缓解这一问题, 本节在固定标注预算 K 下, 从训练集中选择一组能够共同表征主要图像外观模式的样本作为监督起点, 记为 Anchor 集合 $\mathcal{A}$, 其中 $|\mathcal{A}| = K$ 。选择过程仅使用训练图像的 RGB 信息, 不读取任何分割掩码, 也不利用验证集或测试集; 只有在 $\mathcal{A}$ 完全确定后, 才获取对应图像的人工标注, 构成第 3.6 节中的 D_L 。

为衡量不同训练图像所包含局部视觉模式的相似程度, 我们利用冻结的 SAM3 视觉骨干提取局部表征, 并将其转换为图像级视觉词分布。具体而言, 将候选图像缩放至 1008×1008 , 输入 SAM3 图像编码器, 得到 $72 \times 72 \times 1024$ 的特征图。沿两个空间方向均匀选取 8×8 个位置, 得到 64 个局部 token, 并进行 L_2 归一化。随后, 汇总所有采样 token, 采用 MiniBatch K-Means 学习包含 $M = 64$ 个聚类中心的共享视觉词典。每个 token 被分配到最近聚类中心, 从而统计每幅图像中不同视觉词的出现频率。为降低普遍存在的高频模式影响, 我们进一步统计逆文档频率, 并对词频进行加权与归一化, 得到每幅图像的视觉词概率分布

$$\mathbf{p}_i = (p_{i1}, p_{i2}, \dots, p_{iM}). \quad (34)$$

该表示反映不同局部视觉模式在整幅图像中的组成关系, 不依赖病灶掩码。

在此基础上, 采用 Hellinger 映射将分布变换为单

位球面上的向量，并定义两幅图像 x_i 与 x_j 的相似度为

$$k(i, j) = \sum_{m=1}^M \sqrt{p_{im} p_{jm}}. \quad (35)$$

该相似度即两个视觉词分布之间的 Bhattacharyya 系数。

为选择 K 幅能够共同覆盖训练数据主要视觉模式的图像，我们采用 facility-location 形式的集合覆盖目标：

$$F(\mathcal{A}) = \frac{1}{N_c} \sum_{i=1}^{N_c} \max_{a \in \mathcal{A}} k(i, a). \quad (36)$$

在固定基数约束 $|\mathcal{A}| = K$ 下，采用贪心策略逐步选择边际增益最大的图像：

$$a_t = \arg \max_{j \notin \mathcal{A}_{t-1}} [F(\mathcal{A}_{t-1} \cup \{j\}) - F(\mathcal{A}_{t-1})]. \quad (37)$$

由于相似度非负， $F(\mathcal{A})$ 构成单调次模目标，贪心选择具有 $1 - 1/e$ 近似保证。需要说明的是，该保证针对视觉覆盖目标，而非直接针对分割性能。当 $K = 1$ 时，上述贪心过程只执行第一轮，得到的单幅图像即为覆盖性最好的监督起点；该样本与 $K = 1\%$ 时贪心选择的第一轮结果相同。

经过上述过程得到的 Anchor 集合 $\mathcal{A}$ 将作为第 3.10 节语义路由的起点。对于每一幅待处理图像，RouteSAM 将从 $\mathcal{A}$ 中为其选择合适的传播起点，并进一步在 D_U 中检索 Bridge，构建有序语义路径。

3.9 覆盖感知的监督起点选择

本节的目标是在固定标注预算下，选择一组能够共同表征主要图像外观模式的样本作为后续传播起点。记训练候选池为 $\mathcal{C} = \{x_i\}_{i=1}^{N_c}$ ，需要选择的集合为 $\mathcal{A} \subseteq \mathcal{C}$ ，其中 $|\mathcal{A}| = K$ 。选择过程仅使用训练图像的 RGB 信息，不读取分割掩码，也不利用验证集或测试集。

我们利用冻结的 SAM3 视觉骨干提取局部表征，并将其转换为图像级视觉词分布。具体而言，将候选图像缩放至 1008×1008 ，输入 SAM3 图像编码器，得到 $72 \times 72 \times 1024$ 的特征图。沿两个空间方向均匀选取 8×8 个位置，得到 64 个局部 token，并进行 L_2 归一化。随后，汇总候选池中所有采样 token，采用 MiniBatch K-Means 学习包含 $M = 64$ 个聚类中心的共享视觉词典。每个 token 被分配到最近聚类中心，从而统计每幅图像中不同视觉词的出现频率。为降低普遍存在的高频模式影响，我们进一步统计逆文档频率，并对词频进行加权与归一化，得到每幅图像的视觉词概率分布

$$\mathbf{p}_i = (p_{i1}, p_{i2}, \dots, p_{iM}). \quad (38)$$

该表示反映不同局部视觉模式在整幅图像中的组成关系，不依赖病灶掩码。

在此基础上，采用 Hellinger 映射将分布变换为单位球面上的向量，并定义两幅图像 x_i 与 x_j 的相似度为

$$k(i, j) = \sum_{m=1}^M \sqrt{p_{im} p_{jm}}. \quad (39)$$

该相似度即两个视觉词分布之间的 Bhattacharyya 系数。

为选择 K 幅能够共同覆盖训练数据主要视觉模式的图像，我们采用 facility-location 形式的集合覆盖目标：

$$F(\mathcal{A}) = \frac{1}{N_c} \sum_{i=1}^{N_c} \max_{a \in \mathcal{A}} k(i, a). \quad (40)$$

在固定基数约束 $|\mathcal{A}| = K$ 下，采用贪心策略逐步选择边际增益最大的图像：

$$a_t = \arg \max_{j \notin \mathcal{A}_{t-1}} [F(\mathcal{A}_{t-1} \cup \{j\}) - F(\mathcal{A}_{t-1})]. \quad (41)$$

由于相似度非负， $F(\mathcal{A})$ 构成单调次模目标，贪心选择具有 $1 - 1/e$ 近似保证。最终得到的集合 $\mathcal{A}$ 作为后续语义路由的起点集合；只有在该集合完全确定后，才获取对应图像的人工分割掩码。

3.10 面向待处理图像的语义路由构建

上一节得到的起点集合从整体上覆盖了训练数据的不同视觉模式，但对于某一具体未标注图像，并非所有起点都具有相同的传播价值。因此，本节利用已标注样本中的前景区域构造目标条件下的相似性度量，并在此基础上搜索有序传播路径。

与第 3.9 节不同，语义路由阶段统一在 256×256 分辨率下提取特征，以与后续传播保持一致。对于任意图像 x_i ，将其输入冻结的 SAM3 视觉骨干，得到局部 token 集合 $\mathbf{Z}_i = \{\mathbf{z}_{ip}\}_{p=1}^P$ ，并定义图像级描述子

$$\mathbf{g}_i = \text{norm} \left(\frac{1}{P} \sum_{p=1}^P \mathbf{z}_{ip} \right), \quad (42)$$

用于刻画候选中间图像之间的整体视觉连续性。

对于已标注起始样本 $x_a \in \mathcal{A}$ ，将其人工分割掩码映射到 SAM3 的 token 网格，记前景位置集合为 Ω_a ，并定义前景原型

$$\mathbf{u}_a = \text{norm} \left(\frac{1}{|\Omega_a|} \sum_{p \in \Omega_a} \mathbf{z}_{ap} \right). \quad (43)$$

该原型主要描述人工标注目标区域的视觉特征，使后续匹配更加关注需要传播的分割对象。

给定起始样本 x_a 和候选图像 x_i ，计算前景原型与各局部 token 的相似度，并通过 softmax 加权聚合，得到起始样本条件下的候选图像表示 $\mathbf{h}_{a,i}$ 。由此定义目标相关得分

$$s(a, i) = \mathbf{h}_{a,i}^\top \mathbf{u}_a. \quad (44)$$

为消除不同起始样本之间的整体分数偏移，进一步进行中心化校准：

$$\tilde{s}(a, i) = s(a, i) - \mu_a, \quad (45)$$

其中 μ_a 为起始样本 x_a 在整个训练集上的平均目标相关得分。中心化仅消除起始样本间的整体偏移，不改变同一起始样本下不同图像之间的相对关系。

对于待处理图像 x_t ，一条包含 L 个中间图像的候选路径记为

$$\mathcal{R} = (x_a, x_{b_1}, x_{b_2}, \dots, x_{b_L}, x_t). \quad (46)$$

一条有效路径需要同时满足两个条件：中间图像持续包含与起始目标相关的视觉区域，且相邻图像之间不发生过大视觉跳变。为此，定义相邻图像相似度

$$s_{\text{rgb}}(i, j) = \mathbf{g}_i^\top \mathbf{g}_j, \quad (47)$$

并将路径中的目标相关得分与相邻相似度统一记为数值集合 $\mathcal{V}(\mathcal{R})$ 。候选路径评分定义为

$$Q(\mathcal{R}) = \left(\min_{v \in \mathcal{V}(\mathcal{R})} v, \frac{1}{|\mathcal{V}(\mathcal{R})|} \sum_{v \in \mathcal{V}(\mathcal{R})} v \right). \quad (48)$$

两个分量按字典序比较，即优先选择最小路径值更高的候选；仅当最小值相同时，再比较平均得分。该设计优先避免路径中出现局部明显失配的中间状态。

由于穷举所有中间图像组合计算开销较大，采用束搜索逐步扩展候选路径。每次扩展时，根据图像级描述子的余弦相似度从训练集中获得与当前节点相近的候选图像，并利用上述路径评分保留得分最高的部分候选。束宽固定为 32。正式方法中，所有数据集和待处理图像统一使用 $L = 6$ 个中间图像：

$$\mathcal{R}_t^s = (x_a, x_{b_1}, x_{b_2}, \dots, x_{b_6}, x_t). \quad (49)$$

不同路径长度的影响将在实验部分通过消融实验进一步分析。

3.11 基于 SAM3 的渐进式跨图像传播

经过语义路由构建后，每一幅待处理图像 x_t 均对应一条有序路径 $\mathcal{R}_t^s$ 。该路径确定了监督信息从人工标注逐步到达待处理图像的传播顺序。与直接将 x_a 和 x_t 构造成单次跨图像迁移不同，RouteSAM 将中间图像显式纳入传播过程，使目标信息沿相邻图像之间较为连续的视觉变化逐步传递。

为利用 SAM3 已有的时序掩码传播能力，将路径中的图像按顺序组织为一段短伪视频：

$$\mathcal{V}_t = [x_a, x_{b_1}, x_{b_2}, \dots, x_{b_6}, x_t]. \quad (50)$$

这里的“伪视频”并不要求图像来源于真实连续视频，而是将经过语义路由排序后的独立训练图像视为有序帧序列，以复用 SAM3 的跨帧目标保持与掩码传播能力。

所有路径帧均缩放至 256×256 。对于首帧 x_a ，人工分割掩码 y_a 仅用于生成目标的紧致外接框

$$\mathbf{b}_a = \text{Box}(y_a), \quad (51)$$

作为 SAM3 在首帧上的正框提示。除首帧外，中间图像和待处理图像均不提供人工点、框或掩码提示，整个传播过程也不使用文本提示。

在完成首帧初始化后，冻结的 SAM3 按路径顺序执行前向传播：

$$(x_a, y_a) \rightarrow \hat{y}_{b_1} \rightarrow \hat{y}_{b_2} \rightarrow \dots \rightarrow \hat{y}_{b_6} \rightarrow \hat{y}_t. \quad (52)$$

前一帧中建立的目标状态被持续传递到后续帧，使 SAM3 在新图像内容中更新目标位置和分割区域。中间图像的预测掩码仅作为传播过程中内部维护的目标状态，不被视为人工监督，也不读取其真实标注。

从概率角度看，直接传播试图一次完成 $p(y_t | x_a, y_a, x_t)$ ，而 RouteSAM 将其展开为沿语义路径的连续条件传播：

$$p(y_t | x_a, y_a, x_{b_1}, \dots, x_{b_6}, x_t). \quad (53)$$

通过在起始样本与待处理图像之间引入若干语义相关的中间状态，原本较大的跨图像变化被分散到多个相邻传播步骤中，使 SAM3 每一步面对的目标外观变化相对更加局部。

对于每一幅待处理图像，仅保留路径末端得到的目标掩码作为最终传播结果：

$$\hat{y}_t = \text{SAM3Propagate}(\mathcal{R}_t^s, \mathbf{b}_a). \quad (54)$$

若 SAM3 在目标帧产生多个候选对象，则选取模型内部置信度最高的预测作为该路径输出。整个传播过程中 SAM3 参数保持冻结，不进行微调。最终得到伪标注集合

$$\hat{D}_U = \{(x_t, \hat{y}_t) | x_t \in D_U\}. \quad (55)$$

3.12 路由伪监督学习与最终推理

经过上述过程，每一幅未标注图像 $x_t \in D_U$ 均获得一个由固定六桥路径传播得到的伪分割掩码 $\hat{y}_t$ 。本文将人工标注数据与路由伪标注数据共同用于训练任务特定分割模型：

$$\mathcal{D}^* = \mathcal{D}_L \cup \hat{D}_U. \quad (56)$$

本文不额外筛选不同传播深度产生的候选结果，统一采用第 3.11 节得到的固定六桥传播结果作为未标注样本的训练监督。

采用标准 U-Net 作为任务特定分割模型 $f_\theta(\cdot)$ 。人工标注样本的监督损失为

$$\mathcal{L}_{\text{sup}} = \frac{1}{|\mathcal{D}_L|} \sum_{(x_a, y_a) \in \mathcal{D}_L} \ell(f_\theta(x_a), y_a), \quad (57)$$

其中 $\ell(\cdot)$ 由像素级交叉熵损失和 soft Dice 损失组成。未标注样本的伪监督损失为

$$\mathcal{L}_{\text{pseudo}} = \frac{1}{|\hat{D}_U|} \sum_{(x_t, \hat{y}_t) \in \hat{D}_U} \ell(f_\theta(x_t), \hat{y}_t). \quad (58)$$

最终优化目标为

$$\mathcal{L} = \mathcal{L}_{\text{sup}} + \lambda_u \mathcal{L}_{\text{pseudo}}, \quad (59)$$

其中 λ_u 用于平衡人工监督与路由伪监督。

这种训练方式有意保持下游分割学习过程的简单性。RouteSAM 的主要作用不是重新设计伪标签学习损失或构造新的分割网络，而是改善未标注数据上监督信号的来源：首先根据训练数据内部的语义关系构建传播路径，再利用 SAM3 沿该路径逐步扩展人工监督。因此，最终 U-Net 接收到的附加监督主要由跨图

像监督路由过程决定, 无需依赖候选质量预测、模型间审核或多轮伪标签更新。

语义路由和 SAM3 传播均只用于训练阶段。给定测试图像 x , 最终预测直接由训练完成的 U-Net 得到:

$$\hat{y} = f_{\theta}(x). \quad (60)$$

测试过程中不再访问人工标注起始样本, 不需要检索语义相近图像, 也无需重新构建传播路径或调用 SAM3。

参考文献

- Maregu Assefa, Muzammal Naseer, Iyyakutti Iyappan Ganapathi, Syed Sadaf Ali, Mohamed L. Seghier, and Naoufel Werghi. DyCON: Dynamic uncertainty-aware consistency and contrastive learning for semi-supervised medical image segmentation. *arXiv preprint arXiv:2504.04566*, 2025.
- Yunhao Bai, Duowen Chen, Qingli Li, Wei Shen, and Yan Wang. Bidirectional copy-paste for semi-supervised medical image segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11514–11524, 2023. doi: 10.1109/CVPR52729.2023.01108.
- Xiaokang Chen, Yuhui Yuan, Gang Zeng, and Jingdong Wang. Semi-supervised semantic segmentation with cross pseudo supervision. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2613–2622, 2021. doi: 10.1109/CVPR46437.2021.00264.
- Hanyang Chi, Jian Pang, Bingfeng Zhang, and Weifeng Liu. Adaptive bidirectional displacement for semi-supervised medical image segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 4070–4080, 2024. doi: 10.1109/CVPR52733.2024.00390.
- Mohammad Hesam Hesamian, Wenjing Jia, Xiangjian He, and Paul Kennedy. Deep learning techniques for medical image segmentation: Achievements and challenges. *Journal of Digital Imaging*, 32(4):582–596, 2019. doi: 10.1007/s10278-019-00227-x.
- Rushi Jiao, Yichi Zhang, Le Ding, Bingsen Xue, Jicong Zhang, Rong Cai, and Cheng Jin. Learning with limited annotations: A survey on deep semi-supervised learning for medical image segmentation. *Computers in Biology and Medicine*, 169:107840, 2024. doi: 10.1016/j.combiomed.2023.107840.
- Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollár, and Ross Girshick. Segment anything. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 4015–4026, 2023. doi: 10.1109/ICCV51070.2023.00371.
- Yang Liu, Muzhi Zhu, Hengtao Li, Hao Chen, Xinlong Wang, and Chunhua Shen. Matcher: Segment anything with one shot using all-purpose feature matching. *arXiv preprint arXiv:2305.13310*, 2023.
- Xiangde Luo, Minhao Hu, Tao Song, Guotai Wang, and Shaoting Zhang. Semi-supervised medical image segmentation via cross teaching between CNN and transformer. In *Proceedings of the 5th Conference on Medical Imaging with Deep Learning*, volume 172 of *Proceedings of Machine Learning Research*, pages 820–833, 2022.
- Jun Ma, Yuting He, Feifei Li, Lin Han, Chenyu You, and Bo Wang. Segment anything in medical images. *Nature Communications*, 15:654, 2024. doi: 10.1038/s41467-024-44824-z.
- Xinyu Mao, Xiaohan Xing, Fei Meng, Jianbang Liu, Fan Bai, Qiang Nie, and Max Meng. One polyp identifies all: One-shot polyp segmentation with SAM via cascaded priors and iterative prompt evolution. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2025.
- Maciej A. Mazurowski, Haoyu Dong, Hanxue Gu, Jichen Yang, Nicholas Konz, and Yixin Zhang. Segment anything model for medical image analysis: An experimental study. *Medical Image Analysis*, 89:102918, 2023. doi: 10.1016/j.media.2023.102918.
- Juzheng Miao, Cheng Chen, Keli Zhang, Jie Chuai, Quanzheng Li, and Pheng-Ann Heng. Cross prompting consistency with segment anything model for semi-supervised medical image segmentation. In *Medical Image Computing and Computer Assisted Intervention*, pages 167–177, 2024. doi: 10.1007/978-3-031-72120-5_16.
- Nima Tajbakhsh, Laura Jeyaseelan, Qian Li, Jeffrey N. Chiang, Zhihao Wu, and Xiaowei Ding. Embracing imperfect datasets: A review of deep learning solutions for medical image segmentation. *Medical Image Analysis*, 63:101693, 2020. doi: 10.1016/j.media.2020.101693.
- Feilong Tang, Zhongxing Xu, Ming Hu, Wenxue Li, Peng Xia, Yiheng Zhong, Hanjun Wu, Jionglong Su, and Zongyuan Ge. Neighbor does matter: Density-aware contrastive learning for medical semi-supervised segmentation. *arXiv preprint arXiv:2412.19871*, 2024.
- Antti Tarvainen and Harri Valpola. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- Vi Vu, Thanh-Huy Nguyen, Tien-Thinh Nguyen, Ba-Thinh Lam, Hoang-Thien Nguyen, Tianyang Wang,

- Xingjian Li, and Min Xu. From specialist to generalist: Unlocking SAM's learning potential on unlabeled medical images. *arXiv preprint arXiv:2601.17934*, 2026.
- Mengzhu Wang, Jiao Li, Houcheng Su, Nan Yin, Liang Yang, and Shen Li. GraphCL: Graph-based clustering for semi-supervised medical image segmentation. *arXiv preprint arXiv:2411.13147*, 2024.
- Yicheng Wu, Zongyuan Ge, Donghao Zhang, Minfeng Xu, Lei Zhang, Yong Xia, and Jianfei Cai. Mutual consistency learning for semi-supervised medical image segmentation. *Medical Image Analysis*, 81:102530, 2022. doi: 10.1016/j.media.2022.102530.
- Guoping Xu, Xiaoxue Qian, Hua Chieh Shao, Jax Luo, Weiguo Lu, and You Zhang. A SAM-guided and match-based semi-supervised segmentation framework for medical imaging. *arXiv preprint arXiv:2411.16949*, 2024.
- Chenyu You, Weicheng Dai, Yifei Min, Lawrence Staib, and James S. Duncan. Bootstrapping semi-supervised medical image segmentation with anatomical-aware contrastive distillation. *arXiv preprint arXiv:2206.02307*, 2022.
- Mingen Zhang, Yuanyuan Gu, Meng Wang, Lei Mou, Jingfeng Zhang, and Yitian Zhao. YoloSeg: You only label once for medical image segmentation. *Medical Image Analysis*, 112:104093, 2026. doi: 10.1016/j.media.2026.104093.
- Renrui Zhang, Zhengkai Jiang, Ziyu Guo, Shilin Yan, Juntao Pan, Xianzheng Ma, Hao Dong, Peng Gao, and Hongsheng Li. Personalize segment anything model with one shot. *arXiv preprint arXiv:2305.03048*, 2023.
- Yichi Zhang, Jin Yang, Yuchen Liu, Yuan Cheng, and Yuan Qi. SemiSAM: Enhancing semi-supervised medical image segmentation via SAM-assisted consistency regularization. In *IEEE International Conference on Bioinformatics and Biomedicine*, pages 3982–3986, 2024. doi: 10.1109/BIBM62325.2024.10821951.
- Yichi Zhang, Bohao Lv, Le Xue, Wenbo Zhang, Yuchen Liu, Yu Fu, Yuan Cheng, and Yuan Qi. SemiSAM+: Rethinking semi-supervised medical image segmentation in the era of foundation models. *Medical Image Analysis*, 106:103733, 2025. doi: 10.1016/j.media.2025.103733.
- Zerong Zhang and Lianghua He. SAM foundation model and expert model cross prompting framework for semi-supervised medical image segmentation. *Journal of Visual Communication and Image Representation*, 119:104876, 2026. doi: 10.1016/j.jvcir.2026.104876.